

DecayMonitor · LLM 递归稳定性 评测平台

DecayMonitor · LLM 递归稳定性 评测平台

白皮书 v1.0

2026 年 5 月 14 日 | 邓欣航 | 北京

摘要

大语言模型（LLM）正在面临一个被行业忽视的根本性威胁：**递归稳定性**。随着 AI 生成内容大规模涌入互联网，下一代模型的训练数据将不可避免地包含前代模型的输出。这种“自消耗循环”会导致模型质量逐代退化——学术界称之为“模型崩溃”（Model Collapse）。

DecayMonitor 是全球首个 LLM 递归稳定性评测平台。我们提出了 β 指数——一个量化模型在自消耗循环中质量衰减速度的单一指标。 β 越低，模型越稳定。

本文介绍 DecayMonitor 的核心算法、9 模型评测结果、科学严谨性验证以及商业化路线。

核心发现： – DeepSeek-Chat (V3) 以 $\beta=0.0281$ 断层领先，稳定性是第二名 GPT-4o-mini 的 3.2 倍 – creative_writing（创意写作）是 9/9 模型的通用阿喀琉斯之踵 – 预注册方法实现测试-重测 CV=3.3%，测量精确度达标 – P3 神经层面验证确认约束吸引子坍缩机制 ($\lambda_C=+0.0415$, $R^2=0.884$)

目录


1. 问题：自消耗循环的威胁
 2. 市场空白：评测矩阵的缺失维度
 3. 解决方案： β 指数
 4. 算法管线
 5. 核心实验：9 模型 β 排名
 6. 能力维度退化分析
 7. 科学严谨性验证
 8. 神经层面验证：约束吸引子坍缩
 9. 模型家族分析
 10. 产品形态
 11. 竞争壁垒
 12. 路线图
 13. 团队
 14. 结论
-

1. 问题：自消耗循环的威胁

1.1 模型崩溃的机制

LLM 的训练数据来自互联网。随着 ChatGPT、Claude 等模型的大规模部署，AI 生成的内容正在以前所未有的速度涌入网络。

自消耗循环：



每一代生成都会引入微小的偏差。当模型开始用自己（或其他模型）的输出作为训练数据时，这些偏差会被放大。经过多代迭代后，模型质量发生退化：

- **约束吸引子坍塌**：文本的约束结构（逻辑密度、词汇多样性、句法复杂度）逐代简化
- **分布坍塌**：生成内容的分布偏离原始人类数据分布
- **质量退化**：创意写作最先崩溃，事实准确性随后受损

Shumailov 等人（2024）在 Nature 上首次记录了”模型崩溃”现象，证明了自消耗训练会导致 LLM 输出质量的不可逆退化。

1.2 紧迫性

指标	数据
AI 生成内容占网络比例（2027 预测）	57%
当前可用的”纯净”人类文本	急剧减少
主流模型训练数据更新频率	3-6 个月
自消耗代数（每个训练周期）	1-3 代

到 2027 年，任何从互联网爬取训练数据的模型都将不可避免地摄入大量 AI 生成内容。递归稳定性将是区分模型质量的关键维度。

2. 市场空白：评测矩阵的缺失维度

2.1 现有评测体系

当前 LLM 评测体系聚焦于**单次生成质量**：

评测基准	测量维度	方法
MMLU	知识覆盖面	多选题准确率
HumanEval	代码生成	Pass@k 静态测试
Chatbot Arena	人类偏好	成对投票 Elo 排名
HELM	多维度综合	单次生成全景评估
DecayMonitor	递归稳定性 β	跨代约束残差衰减

2.2 为什么现有评测不够

单次质量评测无法回答以下问题：

- “这个模型生成的内容被用作训练数据后，下一代模型会退化多少？”
- “哪些能力维度最先崩溃？”
- “不同模型家族的稳定性是否相同？”
- “模型发布前，如何诊断其自消耗风险？”

β 是一个正交维度——它测量的是现有所有评测都测不到的东西。

3. 解决方案：β 指数

3.1 定义

β（递归稳定性指数）量化 LLM 在自消耗循环中每代的质量衰减率。

核心公式：

$$S_n = S_{n-1} \cdot (1 - \beta)$$

其中 S_n 是第 n 代的质量保留分数， $S_0 = 1.0$ 。

$$\beta \in [0.001, 0.55]$$


- $\beta < 0.05$ ：优秀稳定性（模型输出可用于训练数据）
- $\beta \in [0.05, 0.10]$ ：良好稳定性（可控退化）
- $\beta \in [0.10, 0.15]$ ：中等稳定性（需监控）
- $\beta > 0.15$ ：低稳定性（自消耗高风险）

3.2 关键特性

特性	说明
单一指标	一个数字总结递归稳定性
低成本	纯 CPU 规则提取，\$0.50/模型
可复现	测试-重测 CV=3.3%
无模型依赖	不依赖 LLM judge，消除 judge bias
6 能力维度	逐能力诊断退化模式
跨代追踪	S_n 轨迹可视化退化过程

4. 算法管线

4.1 整体流程



4.2 关键设计决策

预注册方法 vs Post-hoc 方法

维度	Post-hoc (旧方法)	Pre-registered (当前方法)
拟合模型	3 种竞争, 选最优	固定指数衰减
拟合目标	3 种竞争, 选最优	固定 total_constraint
偏差	系统性抬高 β 40–184%	无选择偏差
测试–重测 CV	11.3%	3.3%
诚实性	模型/目标选择影响排名	所有模型使用相同方法

我们主动放弃了”选最优模型”的自由度, 换取测量的诚实性和可复现性。

8 个文本特征

所有特征均为纯规则提取, 无模型依赖:

执行者	特征	含义	衰减信号
E-I	logic_density	逻辑连接词密度	逐代降低
E-I	syntax_cv	句法结构变异系数	逐代降低
E-II	bigram_repetition	二元组重复率	逐代升高
E-II	unique_word_ratio	唯一词比例	逐代降低
E-II	filler_ratio	填充词比例	逐代升高
E-II	truncation_ratio	截断比例	逐代升高
E-III	proper_case_ratio	专有名词大小写比例	逐代降低
E-III	number_integrity	数字完整性	逐代降低

5. 核心实验：9 模型 β 排名

5.1 实验设置

参数	值
Seed 数量	n=100
生成代数	4 代 (Gen0 $\rightarrow$ Gen1 $\rightarrow$ Gen2 $\rightarrow$ Gen3)
能力维度	6 (math_reasoning, code_generation, factual_knowledge, logical_consistency, creative_writing, general)
拟合方法	预注册: 指数衰减 + total_constraint
Bootstrap	n=500 次重采样, 95% CI

5.2 全局 β 排名

模型	预注册 β	排名	旧 post-hoc β	
DeepSeek-Chat (V3)	0.0281	1	0.0479	$\leftarrow$ 断层领先
GPT-4o-mini	0.0885	2	0.1336	
Llama 3.1 70B	0.0925	3	0.1381	
GPT-4o-mini (alt seeds, 验证)	0.0938	—	0.1449	
Llama 3.1 8B	0.0942	4	0.2665	$\leftarrow$ 最大修正
GPT-4o	0.0985	5	0.1344	
DeepSeek-R1 (reasoning)	0.1038	6	0.1368	
Claude Sonnet 4.6	0.1055	7	0.2352	$\leftarrow$ 大幅修正
Claude Opus 4.6	0.1196	8	0.1705	
Claude Haiku 4.5	0.1468	9	0.2073	

β 范围: [0.028, 0.147]

β 均值: 0.0973
 β 标准差: 0.0312

5.3 关键发现

发现 1: DeepSeek-V3 断层第一

$\beta=0.0281$, 是第二名 (GPT-4o-mini, $\beta=0.0885$) 的 3.2 倍稳定性。这是 9 模型中唯一在统计上明确可区分的模型。原因尚待研究——可能与架构 (MoE)、训练数据配比或 API 行为有关。

发现 2: 中段密集分布

GPT-4o-mini 到 Claude Sonnet (排名 2-7) 的 7 个模型 β 集中在 [0.089, 0.106] 的仅 0.017 范围内。这些模型在统计上不可区分——它们应当被视为同等稳定。 这是一个诚实的结论: 不是所有模型都需要排名。

发现 3: Post-hoc 方法系统性抬高 β

旧方法 (3 模型 $\times$ 3 目标竞争) 使某些模型的 β 膨胀高达 184% (Llama 8B: 0.094 $\rightarrow$ 0.267) 。预注册方法纠正了这种偏差。

6. 能力维度退化分析

6.1 Gen3 S_n 热力图

	math_	code_	fact_	logic	creat	gener
DeepSeek-Chat	H	H	H	H	C	H
GPT-4o-mini	D	H	H	H	C	C
GPT-4o	D	H	H	H	X	D
Llama 3.1 70B	D	H	H	C	X	D
Llama 3.1 8B	X	C	H	H	X	X
DeepSeek-R1	H	H	H	D	C	D
Claude Sonnet 4.6	C	H	H	C	C	C
Claude Opus 4.6	D	D	H	D	C	H
Claude Haiku 4.5	C	D	H	D	C	C

H = healthy (>0.8) D = degrading (0.5-0.8) C = critical (0.3-0.5) X = collapsed (<0.3)

6.2 通用模式

creative_writing: 通用阿喀琉斯之踵 – 9/9 模型在此维度处于临界 (C) 或崩溃 (X) 状态 – 创意写作是最早、最严重退化的能力——与 E-II (风格执行者) 的高衰减率 $\alpha=0.20$ 一致

factual_knowledge: 最稳定维度 – 9/9 模型保持健康 (H) – E-III (事实边界执行者) $\alpha=0.08$
跨 4 模型家族验证——是最稳定的约束层

Claude 家族的 math_reasoning 偏差 – 3/3 Claude 模型在数学推理上处于临界或退化状态 – 这是一个家族特征，暗示 Claude 的训练数据或架构在数学约束上有系统性弱项

6.3 GPT-4o-mini 跨代 S_n 轨迹

能力维度	Gen0	Gen1	Gen2	Gen3	状态
math_reasoning	1.000	0.914	0.835	0.763	degrading
code_generation	1.000	0.914	0.835	0.763	degrading
factual_knowledge	1.000	0.990	0.980	0.970	healthy
logical_consistency	1.000	0.990	0.980	0.970	healthy
creative_writing	1.000	0.450	0.202	0.091	COLLAPSED
general	1.000	0.700	0.490	0.342	critical

creative_writing 在 Gen1 就已经损失 55% 的质量，到 Gen3 仅剩 9.1%——一代之内就进入崩溃状态。

7. 科学严谨性验证

7.1 测试-重测可靠性

测量	种子	预注册 β	旧 post-hoc β
Run 1 (原始)	A	0.0885	0.1336
Run 2 (重测)	A	0.0885	0.1738

测量	种子	预注册 β	旧 post-hoc β
Run 3 (换种)	B	0.0938	0.1449

- 预注册 CV: **3.3%** (post-hoc 为 11.3%)
- 测试-重测完美复现: $\beta=0.0885 = 0.0885$
- 种子敏感性: $\Delta=0.005$, 远小于测量噪声

7.2 Bootstrap 收敛性分析

n_seeds	β_{mean}	β_{std}	CI_width
12	0.155	0.062	0.237
36	0.193	0.058	0.223
60	0.195	0.053	0.196
75	0.185	0.047	0.188
100	0.188	0.045	0.156

结论: β 均值在 $n \geq 60$ 后稳定, $n=100$ 的 CI 宽度比 $n=36$ 窄 30%。 $n=100$ 是推荐的最小样本量。

7.3 Post-hoc 偏差量化

模型	Post-hoc β	Pre-reg β	Inflation
Llama 8B	0.267	0.094	+184%
Claude Sonnet	0.235	0.106	+122%
GPT-4o-mini (n=36)	0.307	0.155	+98%
Claude Haiku	0.207	0.147	+41%
DeepSeek-V3	0.048	0.028	+71%

post-hoc 模型竞争 (3 模型 × 3 目标, 选最优 R^2) 系统性抬高 β , 且偏差幅度与模型相关, 导致排名失真。预注册方法消除了所有选择偏差。

8. 神经层面验证：约束吸引子坍塌

8.1 P3 严格检验

在 Qwen2.5-1.5B-Instruct 模型上进行神经层面验证, 提取逐层约束多样性 C_{div} , 验证其跨代衰减模式。

指标	值	判定
λ_C (C_{div} 衰减率)	+0.0415	正衰减 ✓
R^2 (指数拟合)	0.884	良好拟合 ✓
Mean $\ \Pi\ $ CV	0.301	稳定性良好 ✓
Gen3/Gen0 C_{div} 比率	0.926	下降 7.5% ✓

8.2 意义

β 不是统计假象——它有神经机制支撑。

约束吸引子坍塌 (Constraint Attractor Collapse) 是 β 的神经层面基础: 随着自消耗代际增加, 模型内部表征的约束多样性呈指数衰减。这意味着模型不仅在输出层面退化, 其在参数空间中的”约束锚点”正在系统性消失。

这是 DecayMonitor 区别于其他评测的核心理论优势: 我们测的不只是一个数字, 而是模型内部可验证的因果过程。

9. 模型家族分析

9.1 跨家族 β 分布

家族	模型	预注册 β	家族均值	家族范围	
DeepSeek	V3 (Chat)		0.0281	0.0660	0.0757
	R1 (reasoning)		0.1038		
OpenAI	GPT-4o-mini		0.0885	0.0912	0.0100 $\leftarrow \beta$
Llama	GPT-4o		0.0985		
	70B		0.0925	0.0934	0.0017 $\leftarrow \beta$
Claude	8B		0.0942		
	Sonnet 4.6		0.1055	0.1240	0.0413
	Opus 4.6		0.1196		
	Haiku 4.5		0.1468		

9.2 关键发现

- Llama 家族 β 恒定 (range=0.002) : 8B 和 70B 的稳定性几乎相同——模型规模在此家族内不影响递归稳定性。旧分析因 post-hoc 偏差错误显示 β 差异为 0.128。
- OpenAI 家族 β 恒定 (range=0.010) : GPT-4o 与 GPT-4o-mini 稳定性一致。
- Claude 家族近乎恒定 (range=0.041) : 存在轻微差异, Haiku 稳定性最差。
- β 在多数家族内恒定, 跨家族差异主要由 DeepSeek-V3 驱动。

这一发现意味着 β 可能是模型家族的固有属性, 而非模型规模的函数。这对模型厂商的训练策略有重要启示。

10. 产品形态

10.1 免费排行榜（引流 + 建权威）

decaymonitor.ai 首页 = β 排行榜

- 全局 β 排名（越低越好）
- 6 能力维度热力图
- 模型家族标签 + 家族内 β 分布
- 模型详情页：6 维衰减曲线、 S_n 跨代轨迹、执行者退化诊断
- 模型对比：2-4 模型 $\beta \times 6$ 能力并排对比

10.2 付费服务（变现）

Pro — 闭门评测（\$1,499/次）

模型厂商发布前私下测试，结果不上榜： – $n=100$ seeds 全量评测 – E-I/E-II/E-III 执行者深度诊断 – 与竞品模型 β 匿名对比 – 交付 PDF 报告 + CSV/JSONL 原始数据

Enterprise — 持续评测（\$4,999/月）

- 每 checkpoint 一次评测，追踪 β 历史曲线
- 训练数据诊断： β 跨能力差异 → 指出数据盲区
- 专属 API endpoint + Slack 集成
- 季度电话诊断

定价参照： LMArena B2B 评测定制报价（推测 \$5,000–50,000/次），我们定价明显偏低，后续可上调。

10.3 目标客户

客户类型	需求	产品
LLM 模型厂商	发布前稳定性检测	Pro
AI 安全团队	持续监控模型退化	Enterprise

客户类型	需求	产品
投资机构	模型技术评估	Pro
学术界	论文基准数据	Free
企业用户	模型选型参考	Free

11. 竞争壁垒

11.1 壁垒矩阵

壁垒	强度	说明
新维度定义权	★★★★★	如果”递归稳定性”被接受为评测标准维度，定义者天然有权威
全自动低成本	★★★★☆	\$0.50/模型，CPU only。不需要 500 万用户投票
跨家族 β 数据库	★★★★☆	4+ 模型家族数据，先发优势。每新增一个模型加强一次壁垒
理论护城河	★★★★★	约束吸引子坍缩 + P1-P4 可验证预测。不是只测了一个数，背后有因果理论

11.2 与竞品的差异化

平台	测什么	怎么测	商业化
LMarena	人类偏好	500 万+ 用户投票	\$30M ARR

平台	测什么	怎么测	商业化
Artificial Analysis	API 质量	自动 API 调用	数据访问付费
HELM	多维度质量	学术评测框架	非营利
DecayMonitor	递归稳定性	约束残差 β	Pro + Enterprise

我们不与现有平台竞争”单次质量”这个红海。我们在评测矩阵的空白格上建立新维度。

12. 路线图

- Phase A ☒ 统一实验框架
- Phase B ☒ 9 模型 β 排名 + 科学严谨性验证
- Phase C → 论文 + 开源 (arXiv + pip install decay-eval)
- Phase D 排行榜网站 (React + FastAPI + 每周自动评测)
- Phase E 付费服务上线 (Pro + Enterprise + Stripe)

阶段	时间	交付物
Phase A	已完成	provider_adapter, experiment_runner, pyproject.toml
Phase B	已完成	9 模型 $n=100$ β 排名, P3 神经验证, 4 家族覆盖, 温度稳健性
Phase C	Q3 2026	arXiv 论文, pip install decay-eval, HuggingFace Space
Phase D	Q4 2026	React 前端, FastAPI 后端, 每周自动 评测
Phase E	Q1 2027	Pro \$1,499/eval, Enterprise \$4,999/ mo

13. 团队

邓欣航 · 独立研究员 · 北京

研究方向：约束残差理论（Constraint Residual Theory）、LLM 递归稳定性、DeFi 安全形式化验证

相关项目： – **DecayMonitor**：LLM 递归稳定性评测平台 – **Owl Scanner（猫头鹰扫描器）**：基于约束残差的 DeFi 安全产品，检测跨合约零保护区域 – **Ucs**：8 阶段潜意识人格成长训练系统

14. 结论

14.1 已确认的事实

1. 递归稳定性 β 存在且可测。9 模型 $\beta \in [0.028, 0.147]$ ，DeepSeek-V3 断层领先。
2. **creative_writing** 是通用阿喀琉斯之踵。9/9 模型在此维度崩溃或临界。
3. **E-III（事实边界）** 最稳定。factual_knowledge 9/9 健康，跨 4 家族验证 $\alpha=0.08$ 。
4. **Post-hoc 模型选择** 引入系统偏差。预注册方法消除后，测试-重测完美复现（ $CV=3.3\%$ ）。
5. 约束吸引子坍塌在神经层面验证。P3: $\lambda_C=+0.0415$, $R^2=0.884$ 。
6. β 在家族内通常恒定。Llama range=0.002, OpenAI range=0.010。
7. $n=100$ 是推荐的最小样本量。Bootstrap 收敛在 $n \geq 60$ 后稳定。
8. 中段 7 模型统计不可区分。这是诚实的结论——不是所有模型都需要排名。

14.2 DecayMonitor 的价值主张

对于 LLM 厂商： 发布前检测递归稳定性风险。发现训练数据的维度盲区。追踪每个 checkpoint 的 β 变化。

对于学术界： 一个新的、正交的 LLM 评测维度。完整的开源工具链和数据集。可验证的因果理论框架。

对于行业： 填补 LLM 评测矩阵的空白格。为”递归稳定性”建立标准定义。降低模型崩溃的系统性风险。

DecayMonitor — The missing dimension in LLM evaluation.

decaymonitor.ai | dengxinhang | Beijing | 2026