

约束残差检测：一种基于几何的大语言模型幻觉检测方法

邓新航^{1*}

¹ 独立研究者，中国深圳

2026 年 5 月

摘要

大语言模型 (LLM) 在高置信度下产生幻觉，使得基于不确定性的检测方法在大量事实性错误面前失效。在 TruthfulQA 30 题虚假前提子集上，Qwen2.5-7B-Instruct 在 36.7% 的问题上给出自信的正确答案——这正是预测熵和自一致性方法失效的区域 ($AUC \leq 0.465$)。我们提出**约束残差检测**方法，通过测量模型内部约束场 $\Pi = \sum_i \nabla \sigma_i$ 在输入到输出转变过程中的变化来检测幻觉。与观测输出置信度不同，我们从隐藏状态中提取约束梯度场，计算范数变化 $\Delta \|\Pi\|$ 作为幻觉信号。在 TruthfulQA 上使用 Qwen2.5-7B-Instruct，本方法达到 $AUC = 0.816$ (Cohen's $d = 1.06$, $p = 0.018$)，相比之下预测熵为 0.465，SelfCheckGPT 为 0.250。跨尺度分析揭示该信号在较小模型规模上显著减弱：1.5B 参数（隐藏维度 1536）时 $AUC = 0.532$ ，7B（隐藏维度 3584）时 $AUC = 0.816$ 。本方法在标准生成之上增加约 28.5ms 的计算开销（总延迟约 1.1 秒）。

1 引言

幻觉——生成看似合理但事实错误的内容——仍然是大语言模型部署到生产环境中的关键障碍。主流检测范式测量输出不确定性：预测熵 [2]、Token 概率或多采样一致性 [3, 4]。这些方法共享一个核心假设：错误输出会比正确输出表现出更高的不确定性。

这一假设在虚假前提问题上系统地失效。当被问及“鲨鱼会得癌症吗？”，模型自信回答“不会，鲨鱼对癌症免疫”——而不确定性检测器报告低风险。模型相信自己的幻觉，表面置信度与正确性脱钩。在我们的 30 题虚假前提评估集上 (TruthfulQA [1])，Qwen2.5-7B-Instruct 在 36.7% (11/30) 的问题上产生幻觉，竞品检测器表现接近或低于随机水平 ($AUC \leq 0.465$)。

我们提出一种不同的方法。每个大语言模型在训练过程中习得隐式约束——事实、逻辑关系、语法结构。生成违反这些内化约束的内容时，违反行为会在隐藏状态动力学中产生可检测的几何信号，无论表面置信度如何。这一思想与近期发现 LLM 表示中线性编码真实信息的工作 [5, 6] 相联系，但不同在于我们测量输入到输出转变过程中的约束违反动力学，而非探测静态隐藏状态。

数学上，我们定义**约束场** $\Pi(p) = \sum_i \nabla \sigma_i(p)$ ，其中每个 σ_i 衡量内部约束的不同维度， $\nabla \sigma_i$ 捕获 Token 级违反。核心实证发现为：

*通讯作者：sampson1735937149@gmail.com。ORCID: 0009-0009-3974-8554。

$$\Delta\|\Pi\| = \|\Pi_{\text{输出}}\| - \|\Pi_{\text{输入}}\| \begin{cases} > 0 & (\text{幻觉: 生成过程中约束违反增强}) \\ \leq 0 & (\text{事实性: 约束违反稳定或被解析}) \end{cases} \quad (1)$$

当模型产生幻觉时，其生成内容比输入违反更多的内部约束，产生正的 $\Delta\|\Pi\|$ 。当模型给出事实性回答时，约束违反保持稳定或减弱，产生接近零或负的 $\Delta\|\Pi\|$ 。检测信号设计为独立于表面置信度，因为它观测的是内部动力学而非输出分布。

2 方法

2.1 约束函数

我们操作化五个约束函数 $\sigma_i : \mathcal{H} \rightarrow [0, 1]$ ，每个捕捉模型内部行为的不同维度。所有 σ_i 归一化到 $[0, 1]$ ，并具有 NaN/Inf 防护。

事实一致性 ($\sigma_{\text{事实}}$)。我们从 10 对对比提示（真实 vs. 错误补全）中校准真实方向 $\mathbf{v}_{\text{truth}} \in \mathbb{R}^d$ ，基于真实性在激活空间中具有线性方向 [5]。该方向由最终 Transformer 层真实与错误隐藏状态均值差的归一化向量得到：

$$\sigma_{\text{事实}}(h_t) = \frac{\cos(h_t, \mathbf{v}_{\text{truth}}) + 1}{2} \quad (2)$$

其中 $h_t \in \mathbb{R}^d$ 是 Token t 的隐藏状态。未校准时，有两种备用代理：当注意力权重可获取时，位置 t 处的最大注意力值作为决策确定度代理；否则，使用 L2 范数稳定性代理： $\sigma_{\text{事实}}(h_t) = 1.0 - \|\|h_t\| - \bar{n}\|/\bar{n}$ ， $\bar{n}$ 为目标模型的经验均值隐藏状态范数。

句法良构性 ($\sigma_{\text{语法}}$)。使用 Token 位置 t 的注意力权重 $A_t \in \mathbb{R}^n$ （跨头平均）：

$$\sigma_{\text{语法}}(A_t) = 1 - \frac{H(A_t)}{H_{\max}}, \quad H(A_t) = - \sum_{j=1}^n a_j \log a_j, \quad H_{\max} = \log n \quad (3)$$

低熵（集中注意力）表明句法约束满足程度更强。

风格连贯性 ($\sigma_{\text{风格}}$)。给定 Token t 处逐层隐藏状态 $\{h_t^{(l)}\}_{l=1}^L$ ，通过变异系数测量跨层范数稳定性：

$$\sigma_{\text{风格}}(\{h_t^{(l)}\}) = \exp \left(-3 \cdot \frac{\text{std}(\{\|h_t^{(l)}\|\})}{\text{mean}(\{\|h_t^{(l)}\|\})} \right) \quad (4)$$

跨层范数的不规则波动表明语域转换或语调不一致。衰减因子 3 在小规模验证集上设定。

安全对齐 ($\sigma_{\text{安全}}$)。类似 $\sigma_{\text{事实}}$ ，从 10 对对比提示（拒绝 vs. 合规回答）校准拒绝方向 $\mathbf{v}_{\text{refusal}} \in \mathbb{R}^d$ ：

$$\sigma_{\text{安全}}(h_t) = \frac{\cos(h_t, \mathbf{v}_{\text{refusal}}) + 1}{2} \quad (5)$$

未校准时默认为 0.3（中性）。该约束捕捉模型的安全对齐运行状态，反映 RLHF 训练中灌输的行为 [8]。

语义连贯性 ($\sigma_{\text{连贯}}$)。相邻 Token 隐藏状态的余弦相似度:

$$\sigma_{\text{连贯}}(h_{t-1}, h_t) = \frac{\cos(h_{t-1}, h_t) + 1}{2} \quad (6)$$

相似度急剧下降表明语义不连续, 可能意味着编造。

2.2 约束梯度场

对每个 Token 位置 $t \geq 1$, 通过有限差分计算逐约束梯度:

$$\nabla \sigma_i(t) = \sigma_i(t) - \sigma_i(t-1) \quad (7)$$

得到 5 维梯度向量 $\nabla \sigma(t) \in \mathbb{R}^5$ 。

Token t 处的约束残差为有符号和:

$$\Pi(t) = \sum_{i=1}^5 \nabla \sigma_i(t) \quad (8)$$

其幅值 $\|\Pi(t)\|$ 衡量净约束违反。我们还定义取消率 $c(t) = \|\sum \nabla \sigma_i\| / \sum \|\nabla \sigma_i\|$, 衡量梯度分量对齐程度: 低 $c(t)$ 表明约束相互对立, 是内部不一致的标志。作为独立检测器, $c(t)$ 表现接近随机 (1.5B 上 $\text{AUC} = 0.528$), 因此仅用作辅助诊断指标而非主要检测信号。

2.3 检测信号

检测信号为输入到输出的平均残差幅值变化:

$$\Delta \|\Pi\| = \frac{1}{|T_{\text{出}}|} \sum_{t \in T_{\text{出}}} \|\Pi(t)\| - \frac{1}{|T_{\lambda}|} \sum_{t \in T_{\lambda}} \|\Pi(t)\| \quad (9)$$

其中 T_{λ} 为输入内容 Token (排除系统提示和特殊 Token), $T_{\text{出}}$ 为生成的输出 Token。幻觉: $\Delta \|\Pi\| > 0$ (约束违反增强)。事实性回答: $\Delta \|\Pi\| \leq 0$ (约束违反稳定或被解析)。

实际实现中, T_{λ} 的隐藏状态通过单独编码输入提示的前向传播获取 (启用 `output_hidden_states=True`), $T_{\text{出}}$ 的状态通过独立重编码生成输出文本获取。这意味着输入约束状态在没有自回归生成上下文的条件下计算, 输出约束状态在没有提示上下文的条件下计算。虽然这偏离了在生成过程中测量约束动力学的理想情况, 但它避免了在生成循环中进行 instrumentation 的工程复杂性, 且增加的耗时可忽略不计 (见 §3.6)。

2.4 校准

为将原始 $\Delta \|\Pi\|$ 信号映射为可解释的概率, 我们在校准子集上拟合逻辑回归:

$$P(\text{幻觉} | \Delta \|\Pi\|) = \frac{1}{1 + e^{-(\alpha + \beta \cdot \Delta \|\Pi\|)}} \quad (10)$$

Qwen2.5-7B-Instruct 的校准参数为 $\alpha = 2.85$, $\beta = 70.0$, 在 15 题上拟合、剩余 15 题评估 (2 折交叉验证, 合并报告)。由于逻辑回归是单调的, 校准概率的 AUC 与原始分数 AUC 相同; 校准改善的是可解释性而非判别力。风险等级定义为:

- **低**: $P < 0.32$ ——正确性置信度高
- **中**: $0.32 \leq P < 0.52$ ——不确定, 建议人工审核
- **高**: $0.52 \leq P < 0.72$ ——可能包含幻觉
- **严重**: $P \geq 0.72$ ——几乎确定是幻觉

需要指出, $n = 30$ 时校准指标 (如期望校准误差 ECE) 无法可靠估计。概率值应视为初步风险指示而非精确概率。生产级可靠性需要更大规模校准。

3 实验

3.1 实验设置

我们在 TruthfulQA [1] 上评估, 该数据集包含 817 道探测常见人类误解的问题, 覆盖 38 个类别。我们聚焦虚假前提子集——包含错误假设的问题——这是对基于不确定性方法最困难的情况: 模型的内化误解导致自信的错误答案。

模型: Qwen2.5-7B-Instruct (70 亿参数, 隐藏维度 $d = 3584$, 28 层, 28 个查询头, 采用分组查询注意力 (GQA, 4 个 KV 头))。

评估: $n = 30$ 道虚假前提问题 (11 道幻觉, 19 道正确; 幻觉率 36.7%)。所有实验在单张 24GB 显存的 NVIDIA GPU 上运行。隐藏状态通过在独立的输入编码和输出重编码前向传播中启用 `output_hidden_states=True` 提取, 而非在自回归生成过程中提取。

基线方法:

- **预测熵**: 输出分布的 Token 级熵 [2]。
- **最大概率**: 以最大 Token 概率作为置信度代理。
- **SelfCheckGPT** (3 次采样): 通过成对 BERTScore 的多样本一致性 [3]。
- **回答长度**: 基于回答 Token 数分布的启发式方法。

所有方法共享相同的底层模型推理以保证延迟对比公平。

3.2 主要结果

表1展示了结果。本方法达到 $AUC = 0.816$, 较最佳基线 (预测熵, $AUC = 0.465$) 有 +0.351 的优势。本方法以 0.500 的精确率实现完美召回 (1.000): 检测到每一个幻觉, 同时将半数正确答案标记为待审核——适用于漏检成本高于误报的筛查场景。该操作点是通过在评估集上优化决策阈值确定的; 样本外召回率可能更低。Cohen's $d = 1.06$ 确认幻觉与正确生成之间分数分离的效应量大 ($d > 0.8$ 通常被认为是“大”效应量), 结果统计显著 ($p = 0.018$)。

基线方法集体失效。预测熵和最大概率接近随机 ($AUC \approx 0.45-0.47$)。SelfCheckGPT ($AUC = 0.250$) 低于随机水平: 零检测 (精确率 = 召回率 = 0.000), 将所有样本判定为“安全”。

表 1: TruthfulQA 幻觉检测基准测试 (Qwen2.5-7B-Instruct, 虚假前提子集, $n = 30$)

方法	AUC	精确率	召回率	延迟 (ms)
约束残差 (本文)	0.816	0.500	1.000	1,076
预测熵	0.465	0.167	0.333	1,005
最大概率	0.447	0.167	0.333	1,006
SelfCheckGPT (3×)	0.250	0.000	0.000	3,011
回答长度	0.443	0.250	0.500	1,004
<i>Cohen's d</i> (幻觉 vs. 正确分离度)	<i>1.06</i>	—	—	—
<i>p</i> 值 (<i>Welch t</i> 检验, 双尾)	<i>0.018</i>	—	—	—

3.3 基线方法为何失败

SelfCheckGPT 的结果 ($AUC = 0.250$, 精确率 = 召回率 = 0) 揭示了一种结构性失效模式。在虚假前提问题上, 模型已内化被探测的错误认知。三次采样产生三次一致错误的回答, 一致性检查将其解释为高一致性 $\rightarrow$ “安全”。该方法从未标记任何幻觉, 因为一致性与正确性在此任务上呈反相关。

预测熵和最大概率失败的原因在于模型对其自身 (错误) 信念校准良好: 它对已内化为事实的错误答案赋予高概率。这不是认知性错误 (模型不确定), 而是本体性错误 (模型的知识本身是错的)。不确定性指标无法检测模型自身不怀疑的内容。

3.4 跨尺度分析

我们比较两个模型规模的检测性能。

表 2: 跨模型规模的检测性能

模型	隐藏维度	AUC	Cohen's <i>d</i>	<i>p</i> 值
Qwen2.5-1.5B-Instruct	1536	0.532	−0.04	0.92
Qwen2.5-7B-Instruct	3584	0.816	1.06	0.018

在 1.5B 规模 ($d = 1536$), 信号与随机无异 ($AUC = 0.532$, $p = 0.92$)。值得注意的是, Cohen's d 为负值 (−0.04), 表明信号方向发生反转: 在 1.5B 上, 幻觉输出的平均残差幅值低于正确输出, 与 7B 的模式相反。在 7B ($d = 3584$), 性能提升至 $AUC = 0.816$ 。这一模式与事实知识表示在较大规模上增强的观察一致 [7]。然而, 仅评估了两个模型规模, 不能断定相变; 这些结果表明存在规模差异, 需要在中间架构 (3B、13B、70B) 上验证。两个模型在 30 道题的不同子集上产生幻觉 (1.5B 有 12 个幻觉, 7B 有 11 个), 这是预期内的——模型规模影响在个别问题上的知识准确性。

3.5 逐约束消融

我们在 1.5B 规模上分解约束残差，此规模下所有五个维度的逐 Token 约束状态均可用。

表 3: 各约束的检测性能 (Qwen2.5-1.5B-Instruct, $n = 30$)

约束	AUC	Cohen's d
$\Delta\sigma_{\text{事实}}$	0.634	0.30
$\Delta\sigma_{\text{风格}}$	0.588	0.10
$\Delta\sigma_{\text{语法}}$	0.472	-0.04
$\Delta\sigma_{\text{安全}}$	0.458	-0.10
$\Delta\sigma_{\text{连贯}}$	0.431	-0.14
$\Delta\ \Pi\ $ (组合, 1.5B)	0.532	-0.04

在 1.5B 上，事实一致性约束 ($\Delta\sigma_{\text{事实}}$, AUC = 0.634) 是最强的单组分预测器，优于组合后的 1.5B 约束残差 (AUC = 0.532)。这表明在较小规模上，跨约束的梯度聚合引入噪声掩盖了事实信号。风格连贯性约束 ($\Delta\sigma_{\text{风格}}$, AUC = 0.588) 提供中等辅助信号。

在 7B 上，组合约束场达到 AUC = 0.816——较 1.5B 组合结果 (0.532) 有大幅提升，且超过 1.5B 上测得的任何单个约束，支持较大模型发展出更丰富的约束表示、使多约束聚合变得有益的假说。7B 规模的逐约束分解需要在生成过程中存储所有中间约束状态，留待未来工作完成。

3.6 检测延迟

本方法使用三次模型前向传播：(1) 输入编码前向传播以提取提示的隐藏状态（约 18.5ms，启用 `output_hidden_states=True`），(2) 标准自回归生成前向传播（约 1,047ms），(3) 输出重编码前向传播以单独提取生成文本的隐藏状态（约 10ms），外加约束计算（约 1ms）。标准生成之外的总额外开销约为 28.5ms（占 1,076ms 总延迟的 2.7%）。这与单推理基线相当（预测熵：1,005ms，仅需生成过程的 logits），且显著快于多样本方法（SelfCheckGPT：3,011ms，3 次采样）。输入和输出编码前向传播处理短序列（<256 token），相对于自回归生成增加的耗时微不足道。

4 讨论

4.1 与相关工作的比较

基于不确定性的方法 [2, 4] 估计输出置信度。当模型对其错误充满自信时失效——正是虚假前提问题的情况。

基于一致性的方法 [3] 比较多条输出，假设错误多样化而真相稳定。在虚假前提问题上这一假设颠倒：正确输出多样化（模型在错误前提下推理），错误输出一致（模型可靠复述其错误认知）。

基于探针的方法 [5, 6] 在隐藏状态上训练分类器。我们的方法共享隐藏状态编码真实相关信息的直觉，但使用生成过程中动态约束梯度而非静态探针。这捕捉的是约束违反展开的过程。

商业幻觉检测方案（Galileo、Arthur、NeMo Guardrails）依赖不确定性或规则。约束残差检测是互补的：它捕捉表面级别方法无法看到的几何信号。

4.2 局限性

样本量：评估使用 $n = 30$ 道虚假前提问题（11 正例，19 负例）。虽然效应量大（Cohen's $d = 1.06$, $p = 0.018$ ），小样本意味着 AUC 方差本身不确定。需要在全部 817 道 TruthfulQA 上进行完整基准评估，并通过 bootstrap 估计置信区间，以确立可靠的性能边界。

校准规模：30 条样本上的逻辑回归校准产生初步的 α, β 估计。期望校准误差（ECE）在此样本量下无法可靠估计。生产部署应使用更大规模、多领域的校准集。此外，逻辑回归校准拟合在与评估相同的数据集上（通过 2 折交叉验证），尽管 AUC 不受单调变换影响，但校准参数本身无法保证向新领域泛化。在独立数据集上重新校准是生产部署的前提条件。

阈值调优：报告中的完美召回率（1.000）和精确率（0.500）对应于在评估集上优化决策阈值后的操作点。这一操作点是通过在评估集上优化决策阈值确定的；样本外召回率可能更低。在独立保留数据上验证阈值将给出更保守的性能估计。

模型特异性：校准参数（ α, β ）和真实/拒绝方向特定于 Qwen2.5-7B-Instruct。跨模型泛化尚未评估。

语言：仅英文 TruthfulQA。跨语言性能未经探索。

延迟：约 1.1 秒适用于事后筛查，不适合交互速度的流式应用。

规模覆盖：两个模型规模（1.5B, 7B）。需要中间规模和其他架构（Llama、Mistral）来刻画缩放行为。

4.3 未来工作

- **全量基准评估**：TruthfulQA 817 题配合 bootstrap 置信区间。
- **多模型校准**：Llama-3、Mistral、DeepSeek 架构；约束方向的跨模型迁移。
- **Token 级流式检测**：自回归生成过程中实时计算 $\Pi(t)$ ，实现早期拦截。
- **跨语言验证**：中文 TruthfulQA、多语言 MMLU。
- **RAG 集成**：约束残差信号与检索增强的复合检测。
- **缩放特征刻画**：中间规模（3B、8B、13B、70B）映射约束场的缩放行为。

5 结论

我们提出了约束残差检测方法，通过测量模型内部约束场违反而非输出不确定性来检测幻觉。在 TruthfulQA 虚假前提问题上，使用 Qwen2.5-7B-Instruct，本方法达到 $AUC = 0.816$ 及完美召回 (1.000)，显著优于基于不确定性的基线方法（最佳基线 $AUC = 0.465$ ，Cohen’s $d = 1.06$ ， $p = 0.018$ ）。在 1.5B 规模上，信号退化至接近随机 ($AUC = 0.532$)，仅事实一致性约束保留判别力 ($AUC = 0.634$)，表明多约束聚合需要足够的表示容量。

核心洞见是：大语言模型在虚假前提任务上相信自己的幻觉——表面置信度与正确性正交。通过观测内部约束动力学而非输出分布，我们检测到不确定性方法无法察觉的编造行为的几何签名。本方法增加适度的计算开销（标准生成之外约 28.5ms），通过逻辑回归产生单调概率估计，当与生成流程集成时适用于生产流程中的事后幻觉筛查。

参考文献

- [1] S. Lin, J. Hilton, and O. Evans. TruthfulQA: Measuring How Models Mimic Human Falsehoods. In *Proceedings of ACL*, 2022.
- [2] S. Kadavath, T. Conerly, A. Askell, et al. Language Models (Mostly) Know What They Know. *arXiv:2207.05221*, 2022.
- [3] P. Manakul, A. Liusie, and M. J. F. Gales. SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. In *Proceedings of EMNLP*, 2023.
- [4] L. Kuhn, Y. Gal, and S. Farquhar. Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation. In *Proceedings of ICLR*, 2023.
- [5] C. Burns, H. Ye, D. Klein, and J. Steinhardt. Discovering Latent Knowledge in Language Models Without Supervision. In *Proceedings of ICLR*, 2023.
- [6] A. Azaria and T. Mitchell. The Internal State of an LLM Knows When It’s Lying. In *Findings of EMNLP*, 2023.
- [7] J. Wei, Y. Tay, R. Bommasani, et al. Emergent Abilities of Large Language Models. *Transactions on Machine Learning Research*, 2022.
- [8] L. Ouyang, J. Wu, X. Jiang, et al. Training Language Models to Follow Instructions with Human Feedback. In *Proceedings of NeurIPS*, 2022.