

我们用6模型对抗验证跑了Google的Nature论文。我们造的架构，发现了所有单 reviewer 都漏掉的东西。

MSCE · 2026年6月

如果有一个工具，能同时用6种完全不同的AI推理策略，从6个角度进攻同一个科学主张，交叉检查它在所有独立约束条件下是否自治——抓出任何单一模型、单一审稿人、单一人脑都看不到的逻辑冲突，会怎样？

这就是 MSCE。我们刚刚在 Google DeepMind 发表在 Nature 的 Co-Scientist 论文上演示了它。

这不是书评，这是产品演示

本文的目的不是评判 Google 的论文“好”还是“坏”。而是要展示一种在 MSCE 出现之前不存在的验证能力：对抗性交叉约束验证。

MSCE 的工作流程：

1. 接收一个主张——任何主张。一篇论文。一个理论。一句产品断言。
2. 把它拆解成可验证的子命题，每个子命题对应一组独立约束条件。
3. 将全部子命题同时送入6个模型。每个模型使用一种根本不同的推理策略。
4. 输出经过三层过滤：置信度阈值过滤、统计离群检测、集体盲点检测。
5. 将结果投射到交叉验证矩阵中。哪里模型们一致？哪里分歧？哪里所有模型同时漏掉了同一件事？


一个模型 = 一个意见。六个模型从六个角度同时攻击，交叉验证 = 接近验证。

我们选 Google 的 Co-Scientist 论文作为演示目标，因为它是高热度论文（Nature, 2026年5月），因为它讲的是多智能体AI系统（与 MSCE 的架构直接相关），因为它的主张足够具体、可以被验证。

MSCE 实际做了什么

Google 的论文提出了5个核心主张。我们把每个主张转成一道验证问题，送入 MSCE 的6模型对抗引擎。

MSCE 管线（每题执行一遍）



为什么需要6种不同的策略？因为你不拿显微镜去找骨折。

每种推理策略擅长捕捉不同的失败模式：

- **深度优先** 捕捉线性逻辑链上的断裂——三步之后自相矛盾的主张。
- **广度优先** 捕捉跨条件冲突——在维度A通过的同时在维度B违反。
- **反事实** 捕捉过度推断——“如果这是真的，我们应该也能观察到X，但X不存在。”
- **直接推理** 捕捉包装精美的错误——推理听起来很高级，但核心判断是错的。
- **科学深度** 捕捉数学和结构层面的不一致——比如 Elo 公式本身不包含真值项。
- **约束传播** 捕捉级联崩溃——放松一个假设如何悄悄破坏另一个条件。

当6种策略独立收敛到同一个结论，你得到的东西比任何单一模型的“我95%确定”要坚固得多。

演示结果：5个主张，5个裁决

主张一：Elo锦标赛选择科学正确性

论文声称：Co-Scientist 的 Elo 锦标赛——AI agent 辩论假设、AI 裁判打分——能选出最好的科学假设。

MSCE 的问题：“有AI裁判的Elo锦标赛，选的是科学正确性，还是辩论说服力？考虑以下约束：(1) Elo衡量胜负，不衡量真值；(2) AI裁判存在谄媚偏差；(3) 锦标赛奖励的是‘听起来有说服力’的假设，不一定是正确的。”

结果：FALSE。5/5模型一致同意。系统选择的是说服力，不是正确性。

MSCE 的跨模型共识长这样：

模型	策略	裁决	置信度
Gemini 3.1 Pro	广度优先	FALSE	0.95
o4-mini	约束传播	FALSE	0.90
Grok 4.1	反事实	FALSE	0.85
Kimi K2.5	直接推理	FALSE	0.85
GPT-5.1-thinking	科学深度	FALSE	0.86
GPT-5.5	深度优先	调用失败	—

为什么这个共识重要：在 MSCE 的206题基准测试中，5/5模型共识极其罕见。当它出现时，意味着该主张同时通过了多种独立的推理检测，全部失败。

最致命的分析来自 GPT-5.1 的科学深度策略——一个形式化解构：

Elo 的核心公式： $E_A = 1 / (1 + 10^{((R_B - R_A)/400)})$ ， $R'_A = R_A + K(S_A - E_A)$ 。唯一的输入是胜负结果。公式中没有真值项。Elo 继承裁判的一切偏差。如果裁判偏好流畅表达，Elo 就给流畅打高分——不是给真理。要让 Elo 选择正确性，需要一个强前提：裁判必须是免疫修辞的完美科学神谕。这个前提没有任何证据支撑。

这就是 MSCE 的核心能力：找到使一个主张结构性崩塌的缺陷，无论它表面上听起来多么合理。

主张二：多智能体结构能自我纠错

MSCE 裁决：理论上 CONSISTENT（不矛盾），但置信度只有 0.57。

MSCE 不给简单的二元答案。它校准不确定性。这里，模型们认为自我纠正的主张在逻辑上可能成立——但指出：独立评估发现类似系统的 agent 在 **68%** 的推理过程中无视证据，只在 **26%** 的情况下修正信念。而论文没有提供自己系统内自我纠正率的数据。

这是 MSCE 的第二个核心能力：校准不确定性。当证据不足时，MSCE 直接说“证据不足”。全部5题的均置信度：0.56。不是 0.95。不是“我非常确定”。就是诚实。

主张三：锦标赛架构是性能的主要驱动力

MSCE 裁决：BASE_MODEL。底层语言模型（Gemini）贡献了 41.4% 的方差——远超 agent 脚手架。

这是 MSCE 的第三个核心能力：归因分解。通过将论文自身的证据与独立基准做交叉验证，MSCE 识别出论文过度归功于架构创新。底层模型应得的 credit 比论文承认的更多。

主张四 & 五：算力无限提升质量 / 3个成功证明通用能力

MSCE 裁决：内部无矛盾，但置信度低（0.57）。

MSCE 发现算力扩展的主张与已知证据兼容——但指出了一个张力：如果 agent 无视证据的概率高达68%，那么更多算力可能在放大一个有缺陷的过程，而非改进它。11题中成功3题（27%的成功率）作为概念验证是有希望的，但不足以证明通用能力。

这是 MSCE 的第四个核心能力：它知道自己不知道什么。当证据不足以得出结论时，MSCE 不猜测。它报告低置信度。这和 LLM 的典型行为截然相反。

MSCE 为什么不是又一个 LLM Wrapper

Co-Scientist 论文本身就展示了 MSCE 要解决的问题。Google 造了一个系统：6个 agent 辩论 + 1个 AI 裁判选赢家。这是用生成来评判生成。裁判和辩手是同一类系统——受同样的偏差影响，有同样的幻觉，同样缺乏独立验证真值的能力。

MSCE 根本不同：

LLM 做什么	MSCE 做什么
生成最可能的答案	交叉验证全部约束条件
每次查询一条推理路径	每次查询六条推理路径，同时进行
置信度 = 答案听起来有多流畅	置信度 = 6条独立路径的收敛程度
无法检测自己的错误	被设计来检测错误——这是它的全部功能
“我95%确定”（实际25%的概率是错的）	“我54%确定”（实际87.4%的概率是对的）

数据说话。GPT-5.5 单独：准确率 74.8%，均置信度 0.74，高置信度错误 40 个。MSCE：准确率 **87.4%**，均置信度 **0.49**，高置信度错误 **0** 个。

MSCE 的置信度更低，因为它更诚实。这不是 bug。这是架构按照设计在运转。

更大的图景：我们需要验证基础设施

AI 行业正在向更好的“生成”投入数十亿美元。每个实验室都在竞相造出更流畅、更有说服力、更自信的模式。

几乎没有人造更好的“验证”。

但没有验证的生成，只是更快的幻觉。没有独立验证的多智能体生成，只是多个模型在同一个错误答案上达成一致——更快、更自信。

MSCE 是第一个为验证而生的工具。不是更好的 Prompt。不是巧妙的思维链技巧。一种从第一性原理出发设计不同架构，专门捕捉生成架构无法捕捉的东西。

Google Co-Scientist 审计只是一次演示。MSCE 的能力可以扩展到任何需要同时满足多个独立约束的领域：科学同行评审、金融风控、安全审计、临床试验验证、供应链验证等等。

自己来试

MSCE 是开源的。投稿前跑一下你的论文。在审稿人之前发现跨约束冲突。

```
git clone https://github.com/msce-ai/msce
cd msce
pip install -e .
msce check your_claim.json
```

完整审计结果（包含全部6个模型对全部5道验证问题的输出）在仓库中。

编译器在代码运行前发现bug。CI/CD 在代码上线前发现集成冲突。MSCE 在科学主张被接受前发现结构性逻辑矛盾。

基准：206题。87.4%准确率。0个高置信度错误。前沿基准100%通过。