

LeWorldModel 的架构盲区： LeCun 没看到什么

独立架构评审 · 2026年6月

MSCE 已标记 LeCun LeWorldModel 的5条过度宣称。但问题比过度宣称更深。架构本身存在根本性的结构缺陷——没有审稿人发现。以下是设计层面的断裂点、如何从第一性原理修复、以及为什么“世界模型”需要的远不止视频预测。

一、三个根本性结构缺陷

第一层：潜在空间容量固定，没有自适应增长机制

LeWorldModel 使用 ViT-Small 编码器（8M参数）将视觉输入压缩到固定维度的潜在向量 z_t ，然后预测 z_{t+1} 。当世界中出现训练分布之外的新模式——一个新的物理现象、一个未见的事件序列——编码器只能将其挤压进现有固定容量的空间。

挤压产生的预测误差只用来更新预测器的权重。它永远不会扩展潜在空间的维度来容纳新结构。这是一个封闭系统：输入可变，容量不变。

现实世界的复杂度是开放式的。固定容量的潜在空间有天花板，不管初始多大。LeCun 自己批评语言模型是因为“语言无法捕捉世界的全部结构”。但 LeWorldModel 的潜在空间有着同样的固定尺寸瓶颈。输入模式从文本换成了视频——表示能力的上限没有变。

第二层：没有结构精简机制，所有知识在训练时一次性冻结

在海量视频数据上训练。预测。收敛。部署。部署之后，知识结构就不可变了。

模型不能忘记不再有用的模式。不能为新模式腾出空间。微调可以在同一架构内调整权重——但它永远不会修改架构本身。你不能在运行时说：“我发现了一个全新的模式类别，我需要一个专门的表示通道来处理它。”你只能在现有权重上微调。

第三层：没有跨模态相位校准机制

LeWorldModel 在视频上训练帧预测。但一个声称能表示“世界”的模型，需要理解跨模态的时间对齐关系。视觉和听觉。语言和世界状态。行为和结果。

当你看到一个人举起杯子（视觉流），同时听到“我要喝水”（语言流），一个真正的世界模型必须能检测到这两个不同模态的事件在时间上对齐、指向同一个世界事件。

LeWorldModel 没有独立的跨模态相位校准机制。视频自带同步的音频和字幕——对齐关系被编码在数据里。但当系统遇到新的、没有标注对齐关系的跨模态事件时，它无法判断“这个视觉变化”和“那个语言表达”是否指向同一个世界事件。

二、从第一性原理重新设计

在 LeCun 的 JEPA 框架之上叠加三个核心机制：

动态容量分配。 将固定维度的潜在向量替换为可扩展的表示库。当预测器在某个输入模式上持续产生高误差，系统自动分配新的表示通道专门处理该类模式。通道可以增长、合并或删除。系统自己决定需要多少通道——而不是由超参数预设。

在线结构修剪。 持续监控每个通道的使用频率和预测贡献。如果某个通道长时间未被使用，或其贡献可被其他通道的组合完全替代，则回收。这防止了无限增长，同时实现持续自我优化。模型不会停留在训练时的结构——它在使用中不断重构。

跨模态时间锚定。 加入独立的时间对齐模块。它不参与具体预测，只做一件事：检测不同模态输入流之间的时间相关性。当视觉事件边界和语言 token 边界在时间上高度相关时，标记为“可能指向同一个世界事件”。这个模块不需要标注的跨模态数据——它只依赖时间相关性的统计信号。

三、LeCun 对 LLM 的判断是对的，但他自己的方案不够

LeCun 的论题：语言模型不是通往智能的路径。世界模型才是。方向对。实施不够。

语言模型只接触现实的一个薄层投影。即使一个模型完美预测每一个下一个 token，它也不知道水是湿的、摔倒会疼、“生日快乐”承载的意义超出了 token 概率。这就是符号奠基问题，LeCun 指出来是对的。

但 LeWorldModel 和大语言模型在架构本质上属于同一类：固定容量、固定结构、训练一次。输入模态从文本换成了像素——架构哲学没有变。

很多系统能预测世界。卡尔曼滤波器能。PID 控制器能。天气预报模型能。没人称它们为智能。

心智模型的本质特征不是预测。是自我重构。 当世界的变化超出了模型的预测能力，模型不只是调整权重，而是改变自己的结构去容纳。语言模型做不到。LeWorldModel 也做不到。它们都是在固定架构内优化参数的系统。它们都缺乏从经验中生长出新结构的能力。

LeCun 的方向是对的。终点是对的。但他造的那辆车——LeWorldModel——仍然和他批评的语言模型同属一个架构属。他的世界模型和一个真正的“世界心智模型”之间，恰好差一个能力：让架构自己长出新的结构。

这不是对 JEPA 的否定。JEPA 是一个合理的方向。但一个不能自我重构的世界模型不是世界模型。它是一个带摄像头的固定容量预测器。