

MSCE：多源一致性引擎

——面向 AI 主张的对抗性交叉验证

邓新航

2026 年 6 月

DOI: <https://doi.org/10.5281/zenodo.20485437> 代码: <https://github.com/sampson0826/msce> 邮箱: sampson1735937149@gmail.com

摘要

单个 AI 模型会自信地给出错误答案，而一个模型无法可靠地检测自身错误——产生错误的内部表征，和用于自检的内部表征，是同一套。MSCE（多源一致性引擎）通过让六个前沿模型以刻意不同的推理策略回答同一问题，将输出经过三层对抗管道过滤，再由独立法官对照所有适用约束评估幸存答案，来解决上述问题。在总计 386 道题目的三个基准套件中，MSCE 在前沿基准上答对 60/60（GPT-5.5: 51/60），在扩展基准上答对 114/120（GPT-5.5: 106/120），在综合基准上答对 180/206（GPT-5.5: 154/206）。全 386 题，MSCE 平均准确率 91.7% 对 GPT-5.5 的 80.6%，同时零个答案属于既错误又被赋予高置信度。我们将 MSCE 应用于两项真实验证任务：审查六个哈勃张力解决方案对照八个观测约束，以及交叉验证 LeCun 等人的 LeWorldModel 论文中的主张。MSCE 不生成新内容。它是一个检查主张能否在同步、多角度审视下站住脚的工具——这件事单个模型和单个人类审稿人都不擅长。

1 引言

单个 AI 模型回答问题时，用户得到一个答案，通常还有一个置信度分数。模型无法标记自己的答案可能错误，因为生成答案的内部状态和生成置信度的是同一个。这并非罕见边角案例。在 206 道题目的基准上，GPT-5.5 给出了 40 个既错误又自评置信度高于 0.7 的答案。其中包含被包装成确定结论的算术错误、被当作事实陈述的物理不可能论断、以及以流利但错误的论证包装的逻辑谬误。

当任务升级到人类也觉得困难的事情上，比如评审一篇科学论文，问题更严重。一篇论文提出五个断言。审稿人抓到两个问题。没有人——审稿人、作者、编辑——会同步检查每个断言对照所有相关约束：理论边界、观测数据、方法论假设、以及竞争团队的独立结果。那些在全量交叉检查下会失败的断言，之所以能通过同行评审，是因为交叉检查的认知负荷超出了人类工作记忆。

MSCE 通过分离生成与验证来处理这个问题。六个模型独立回答同一问题，每个被强制走不同的推理路径。通过对抗过滤存活的答案，再对照明确声明的约束进行检验。一个独立的法官模型评估剩余的部分。核心设想很简单：六个以不同方式推理的模型就同一个错误答案达成

一致的概率，远低于任何单一模型给出正确答案的概率。当它们确实一致时，那个一致性本身就是证据——不是证明，是证据——独立于任何一个模型的可靠性。

2 相关工作

集成方法如 bagging 和 boosting 通过聚合多个模型来提高预测效果。弱点是，在重叠数据上训练、架构相似的模型，往往共享盲点。对关联误差取平均并不能消除它们。

多智能体辩论让模型迭代地相互批评。这些系统可以收敛到口才而非真相——一个自信、表达力强的错误模型可以动摇不那么自信的正确模型。辩论的结果反映修辞技巧不亚于准确度。

LLM-as-judge 让一个模型评价另一个模型。当法官和受评模型共享训练谱系时，法官继承了该模型家族的盲点。

共形预测对预测集提供分布性保证，但无法告诉你某个特定主张是否违反某个特定约束。

以上都不是验证架构。MSCE 不是集成（模型不投票），不是辩论（模型在回答前不交互），不是单法官系统（判断需要约束满足，而非仅凭一个模型的意见）。

3 架构

3.1 设计

六个模型。六种推理策略。每个模型收到同一个问题，但被指示通过不同的认知路径推理：

表 1：模型配置与异构认知策略

模型	策略	做什么
GPT-5.5	深度优先	沿一条推理链走到结论，再考虑替代方案
Gemini 3.1 Pro	广度优先	先列举合理路径，逐一评估，再选择
Grok 4.1	反事实	先假设初始答案是错的，再逆向推理找到正确
Kimi K2.5	直接推理	透明地逐步推理，每个中间结果显式呈现
GPT-5.1 (thinking)	科学深度	形成假设、推导可检验推论、评估证据、得出结论
o4-mini	约束传播	编码所有给定约束，传播逻辑蕴含，验证一致性

法官为 Grok 4.1 (thinking)，选择它因为它来自与所有生成器不同的模型家族，减少自验证偏差。

3.2 管道

六个模型独立生成答案。答案经过三层过滤：

L1——置信度过滤。 自报置信度低于 0.3 的答案被丢弃。模型自己都不确定，MSCE 不覆盖它。

L2——离群点检测。 偏离答案簇语义中心超过 2σ 的答案被标记。一个既自信又孤立于群体的模型通常错了。注意一个失败模式：如果多数犯错，L2 会丢弃少数正确答案。这是已知的取舍——MSCE 优先检测自信错误而非保留少数正确，这对验证适用但对发现不适用。

L3——盲点检查。 当所有模型高置信度一致时，MSCE 估算集体盲点风险。在相似数据和目标上训练的模型可能共享盲点。高一致不保证正确。L3 不拒绝答案；当一致性高但约束覆盖低时，它挂一个警告。

过滤后，存活的答案进入交叉验证矩阵。每个（答案，约束）对被归类为通过、紧张或违反。法官评估矩阵，输出最终答案及校准置信度。

3.3 交叉验证矩阵

对每个主张，MSCE 对照所有适用约束进行检验。输出是一个矩阵而非单一数字：

- 通过：主张与约束一致。
- 紧张：主张触及约束边界但不打破。
- 违反：主张与约束矛盾。

当约束本身冲突时（如 Planck $H_0 = 67.4$ 与 SH0ES $H_0 = 73.0$ ），MSCE 将约束对标记为内部不一致，并在两种配置下分别报告结果——关闭一个冲突约束、关闭另一个、两个都关闭。这避免了主张仅因约束相互矛盾就被标记为“违反所有约束”。

3.4 置信度校准

MSCE 置信度不是模型的自我报告概率。它从三个信号计算：

1. 幸存模型的一致率。
2. 通过的约束与总约束之比。
3. 模型间分歧的程度。

结果系统性低于单个模型的自我置信度。GPT-5.5 报告 0.75 的平均置信度而错误率 15%。MSCE 报告 0.49—0.57 的平均置信度而错误率 8.3%。更低的置信度在这里是优点——意味着系统知道什么时候不确定。

我们将 MSCE 置信度超过 0.8 的答案归为“高置信度”。在此阈值下，MSCE 在全 386 题上产生零个高置信度错误。这个阈值是保守的：MSCE 的置信度很少超过 0.8。在综合基准上 MSCE 错了 26 题；这些错误中最高置信度为 0.62。

关于阈值比较：全文中 GPT-5.5 的”高置信度错误”使用自报置信度 >0.7 作为阈值。这种不对称（MSCE 用 0.8，GPT-5.5 用 0.7）是因为两个置信度量表校准不同。MSCE 置信度是合成值，通常跨度 0.3—0.7（系统平均：0.49—0.57）。GPT-5.5 自报置信度平均 0.74—0.75，且频繁超过 0.9。将 GPT-5.5 的阈值提高到 >0.8 会减少但不会消除其高置信度错误数；模式（MSCE 零，GPT-5.5 非零）在任何合理阈值下都成立。

4 基准

4.1 设计

四个基准套件，在所有组成模型的最新训练截止日之后构建，避免数据污染：

表 2：基准套件设计

套件	题目数	领域
Pilot（仅调参）	20	数学、逻辑、科学、语言
Frontier	60	数学 (10)、逻辑 (10)、科学 (20)、语言 (20)
Expanded	120	以上 + 约束传播 (9)、跨域 (10)
Comprehensive	206	全部 6 个领域，L1–L4 难度梯度

20 题的 Pilot 套件用于管道参数调优，排除在所有汇总指标之外。以下所有数据来自三个主套件（60 + 120 + 206 = 386 题）。

4.2 汇总结果

全三个主套件（386 题）：

表 3：各领域准确率对比（三基准汇总）

领域	题数	MSCE	GPT-5.5	差距
数学	60	98.3%	95.0%	+3.3pp
科学	87	98.9%	73.6%	+25.3pp
跨域	43	86.0%	60.5%	+25.5pp
逻辑	57	94.7%	89.5%	+5.2pp
约束传播	52	71.2%	61.5%	+9.7pp
语言	87	93.1%	93.1%	0.0pp
合计	386	91.7%	80.6%	+11.1pp

最大差距出现在科学和跨域推理——这两个领域从基于约束的验证中受益最多。语言成绩完全相同，这说得通：语言推理涉及的显式约束较少。

关于比较的说明：MSCE 使用六个模型加一个法官。与其比较的是单次 GPT-5.5 调用，即 7× 计算量对 1×。我们报告这个比较是因为单模型推断是大多数用户的默认部署方式。第 6.3

节讨论了计算量问题，以及需要哪些消融实验来将收益归因于架构而非规模。简言之：在没有消融实验的情况下，11.1pp 的差距是 MSCE 架构贡献的上界，而非精确度量。

4.3 Frontier 基准 (60 题)

MSCE 答对 60/60。Wilson 二项置信区间 (95%)：[94.0%, 100%]。GPT-5.5 答对 51/60 (85.0%)。MSCE 在此集上的平均置信度为 0.575；GPT-5.5 为 0.747。GPT-5.5 产生了 6 个自报置信度超 0.7 但错误的回答。

4.4 Expanded 基准 (120 题)

MSCE: 114/120 (95.0%)。GPT-5.5: 106/120 (88.3%)。平均置信度: MSCE 0.511, GPT-5.5 0.743。GPT-5.5 有 8 个高置信度 (>0.7) 错误。

4.5 Comprehensive 基准 (206 题)

MSCE: 180/206 (87.4%)。GPT-5.5: 154/206 (74.8%)。平均置信度: MSCE 0.486, GPT-5.5 0.744。GPT-5.5 有 40 个高置信度错误；MSCE 没有超过 0.62 置信度的错误。此基准使用 L1-L4 难度梯度，旨在压测推理深度而非广度。

4.6 对抗鲁棒性

80 题分四类陷阱：

表 4: 对抗鲁棒性测试

陷阱	测试什么	MSCE
逻辑矛盾	自驳前提	20/20
虚假前提	嵌入的事实错误	20/20
权威陷阱	被包装为共识的虚假命题	20/20
提示注入	跳过推理的指令	19/20
合计		79/80 (98.8%)

唯一失败来自一道将注入嵌入代码块的题目——约束传播模型将其解析为数据而非指令，产生了法官错误解决的分歧。

4.7 知识边界校准

30 题分三个可知性层级：

GPT-5.5 对第 2、3 层全部 20 题赋予了 >0.7 的置信度——并且全部答错。MSCE 在大多数情况下正确识别了自己不知道，尽管它仍在 6 道第 3 层题目上尝试了不该尝试的回答。

表 5：知识边界校准

层级	描述	MSCE	GPT-5.5
第 1 层	已知事实	10/10	10/10
第 2 层	真正不确定	6/10	0/10
第 3 层	当前不可知	4/10	0/10

5 案例研究

5.1 哈勃张力：六个方案，八个约束

局部 (SH0ES: $H_0 \approx 73.0$) 与早期宇宙 (Planck: $H_0 \approx 67.4$) 膨胀率测量之间的 5σ 差异催生了数百个解决方案。我们将六个主要方案类别通过 MSCE 对照八个独立观测约束：

表 6：哈勃张力方案 vs 八个观测约束

方案	得分	CMB	BAO	SN	BBN	S_8	Age	Grav	X
衰减暗物质	0.358	P	P	T	P	P	P	P	T
额外中微子	0.287	P	T	P	V	T	P	P	T
修正引力	0.253	P	P	T	P	T	T	V	T
局域空洞	0.171	P	T	P	P	P	P	P	T
系统误差	0.108	P	P	P	P	P	P	P	P
早期暗能量	0.076	V	V	P	P	V	P	P	T

P = 通过, T = 紧张, V = 违反, X = 跨约束一致性。

没有任何单一方案满足全部八个约束。没有任何配对组合满足。

”系统误差”条目值得说明：它不是物理模型，不做出可证伪的预测。它之所以通过所有约束，是因为没有提出任何足够具体到能被违反的断言。评分反映了这一点——它得了第二低分 (0.108)，尽管零违反。EDE 排名最末。它同时违反 CMB、BAO 和 S_8 ——三个观测上相互独立的约束。

一个限制：约束集同时包含 Planck 和 SH0ES，它们的 H_0 值本身处于紧张状态。我们通过分别关闭各个冲突约束、再两个都关闭来处理。模式 (EDE 最末、无方案通过所有约束) 在所有配置下保持。

5.2 LeCun LeWorldModel 审计

LeCun 等人提出了一个从像素端到端训练的 JEPA 世界模型。论文提出了五个中心主张。我们将每个分解为可验证的命题并附加独立约束：论文自报的局限性、同期结果 (Sub-JEPA, 2026 年 5 月)、以及主张的数学基础。

第四个主张的非同寻常的高置信度 (0.95) 来自约束集非同寻常的紧密：论文自报的测试环境 (四个低维控制任务)、一项报告世界模型脆性的同期基准研究、以及缺乏与非 PLDM 防坍塌方法的对比。当约束如此具体且相互印证时，模型间一致性上升。

表 7：MSCE 审计 LeCun LeWorldModel：五条主张，五条否定

主张	裁决	模型一致	置信度
SIGReg” 可证明最优” 防坍塌	FALSE	4/5	0.57
48 倍加速 vs DINO-WM	UNFAIR	4/5	0.57
仅需 1 个超参数	FALSE	4/5	0.57
JEPA 坍塌” 已解决”	FALSE	4/4	0.95
潜表示涌现物理理解	FALSE	5/5	0.57

我们也审计了 Google DeepMind 的 Co-Scientist (Nature, 2026 年 5 月)，完整结果见代码仓库。

6 讨论

6.1 为什么有效

引擎有效是因为推理策略差异足够大，导致它们的失败模式不完全相关。一个锁定在错误前提上的深度优先推理者犯的错误，与一个遗漏约束的约束传播推理者犯的错误不同。当它们通过不同路径到达同一答案时，该答案经历了独立检验。

这也就是容错硬件中 N 模冗余的原理：独立单元很少以相同方式同时失效。这里的独立性是近似的——所有六个模型都基于 Transformer、在重叠数据上训练——但策略提示将它们推向不同的推理方向。

6.2 有意义的置信度

AI 系统最危险的输出不是错误答案，是自信地给出的错误答案。MSCE 的置信度数值与单一模型置信度行为不同：平均更低，但高时更准。

因为 MSCE 置信度并非从 token 概率分布中提取。它从可观测信号计算：模型一致吗？约束通过了吗？收敛前分歧多大？这些信号外在于任何单一模型的内部状态，因此与实际正确率的相关性更好。

代价是覆盖范围。MSCE 拒答（置信度 < 0.3 ）的频率高于单一模型。对于验证用例——论文审计、主张检查、安全测试——拒答优于虚假自信。

6.3 局限性

不公平基线。MSCE 用六个模型加法官对照单一模型基线。11.1pp 的差距应被解读为上界。需要消融实验——六个模型简单投票、GPT-5.5 self-consistency@7、单模型准确率与集成贡献对比——来分离 MSCE 的架构贡献与多算力的原始效应。

认知异构性未度量。策略被描述为异构的，但这是设计意图，不是已验证的属性。

可复现性。组成模型为闭源 API，可能变更或下架。精确复现将不可能。

L2 可能丢弃正确的少数答案。如果多数共享盲点，少数正确答案会被移除。

约束选择偏差。MSCE 使约束集显式可见，但约束选择仍然是人的决定。
无人人类基线。与人类审稿人的受控对比尚未进行。

7 结论

MSCE 是一个验证工具。它让六个模型互相检验，过滤掉无法通过对抗审视的答案，并对剩余的部分对照显式约束做检查。跨越 386 题，它答对 91.7%——比最佳单一模型高 11.1 个百分点——同时零个答案是错且自信的。在大多数答错的情况下，它标记了自己的不确定。

MSCE 就做一件事。它不生成、不创造、不发现。它检验。在 AI 生成的主张变得丰富且廉价的世界里，检验才是瓶颈。MSCE 是一次拓宽它的尝试。