

# StabilityBench 战略计划书

## StabilityBench 发布、引用链建设与营销战略计划书

邓新航 | 2026年5月

### 一、项目现状

#### 1.1 论文状态

- 英文版: Recursive Stability Index: A Prospectively Committed Framework for Measuring Multi-Generation Semantic Stability in Large Language Models
- 中文版: 递归稳定性指数：一种前瞻性锁定方法论的大语言模型多代语义稳定性测量框架
- 中英文双版 PDF 已生成
- 12防线验证全部完成（见下）

#### 1.2 防线矩阵

| # | 防线       | 结果                          | 状态 |
|---|----------|-----------------------------|----|
| 1 | 前瞻性方法论锁定 | 消除 32-183% 后验偏误             | ✓  |
| 2 | 重测信度     | 两次独立运行 $\beta$ 完全一致         | ✓  |
| 3 | K=5 指数验证 | 3模型×7维度=21/21 指数胜线性         | ✓  |
| 4 | 跨种子源验证   | n=5, Spearman $\rho$ =0.800 |    |

| #  | 防线                  | 结果                                           | 状态 |
|----|---------------------|----------------------------------------------|----|
|    |                     |                                              | ✓  |
| 5  | Bootstrap 置信区间      | 16模型95%CI, 顶端底端不重叠                           | ✓  |
| 6  | 温度稳健性               | $\Delta\beta < 0.014$ ( $T \in [0.0, 1.0]$ ) | ✓  |
| 7  | 基线对比-熵              | Spearman $\rho=0.00$                         | ✓  |
| 8  | 基线对比-TTR            | Spearman $\rho=0.00$                         | ✓  |
| 9  | P3 神经验证             | $R^2=0.884$ ( $\lambda_C$ 对消约束增长)            | ✓  |
| 10 | 后验膨胀数据              | 透明报告 32-183%                                 | ✓  |
| 11 | 下游任务验证              | $n=14, r=0.004$ — 诚实标注为开放问题                  | ⚠  |
| 12 | creative_writing 瓶颈 | 13/16模型 + 约束层级解释                             | ✓  |

### 1.3 核心竞争优势

- **首创性**：递归稳定性是 AI 评测空白地带， $\beta$  是第一个也是目前唯一一个量化指标
- **成本壁垒**：\$0.50/模型 vs GPU 评测数千美元，高频更新可行
- **因果解释力**：约束残差框架给出”why”，不只是”what”
- **数据深度**：16 模型  $\times$  6 维度  $\times$  跨种子源  $\times$  K=5 深度扩展，数据集业内最全
- **诚实性**：null result 透明报告  $\rightarrow$  信号可信度

---

## 二、Phase 1：发表与优先权建立（本周）

---

### 2.1 arXiv 提交

**操作步骤：** 1. 注册 arxiv.org 账号（需要学术机构邮箱或被 endorser 邀请） 2. 若无学术邮箱，可选路径： – 找有 arXiv 账号的合作者代提交 – 使用 institutional email 注册 3. 提交英文版 PDF 4. 学科分类：cs.AI（人工智能）、cs.CL（计算语言学）、stat.ML（机器学习）

**时间节点：** 提交后 48–72 小时获得 arXiv ID

**战略意义：** arXiv ID = 不可逆的优先权时间戳。任何人此后写递归稳定性必须引用你。

## 2.2 Zenodo 数据存档 + 真实 DOI

**打包内容：** – 论文 PDF（英文版 + 中文版） – 16 模型全量 JSONL 谱系数据 – all\_models\_summary.json（全局  $\beta$  排名） – baseline\_comparison.json（熵/TTR 基线对比） – bootstrap\_cis.json（Bootstrap 置信区间） – cross\_seed\_comparison.json（跨种子源验证） – k5\_analysis.json（K=5 指数验证） – p3\_results.json（P3 神经梯度分解） – preregistered\_analysis.json（后验膨胀数据）

**操作步骤：** 1. 创建 zenodo.org 账号（支持 GitHub 登录） 2. 创建新上传（New Upload） 3. 填写元数据：标题、作者、摘要、关键词 4. 上传打包的 ZIP 文件 5. 获取 DOI（格式：10.5281/zenodo.XXXXXXX） 6. 将 DOI 插入论文

## 2.3 GitHub 仓库

**仓库结构：**

```
stability-bench/
├── README.md           #  $\beta$  解释 + 16模型排名 + 复现指南
├── LICENSE             # CC BY 4.0
├── CODE_LICENSE        # MIT
├── paper/
│   ├── main.md         # 英文论文
│   ├── main_cn.md      # 中文论文
│   ├── main.pdf        # 英文 PDF
│   └── main_cn.pdf      # 中文 PDF
├── experiment_data/    # 全量实验结果（公开）
│   ├── all_models_summary.json
│   ├── baseline_comparison.json
│   ├── bootstrap_cis.json
│   ├── cross_seed/
│   └── cross_seed_comparison.json
```

```

|   |   └─ *_report.json
|   └─ k5/
|   |   └─ k5_analysis.json
|   |   └─ *_report.json
|   └─ preregistered_analysis.json
└─ analysis/                                # 分析脚本（公开）
    └─ analyze_cross_seed.py
    └─ analyze_k5.py
    └─ compute_baselines.py
    └─ compute_bootstrap_cis.py
└─ synthetic_decay_monitor/                # 核心框架（公开）
    └─ ...
└─ run_single_model.py                    # 单模型实验脚本
└─ .gitignore                            # 排除闭源资产

```

**闭源保护 (.gitignore) :** – 种子提示词库（核心壁垒——别人读论文理解  $\beta$  但跑不出可比数值） – hybrid extractor 标定参数 – .env（API 密钥）

**README 内容框架:** – 一句话:  $\beta$  测量 LLM 在递归生成下的稳定性 – 16 模型排名表（带 CI） – 核心发现: creative\_writing 是通用瓶颈 – 5 分钟快速开始指南 – API 成本: \$0.50/模型

---

## 三、Phase 2: 引用链播种（第 1–3 个月）

---

### 3.1 学术引用链核心策略

**为什么引用链重要:** 1. 优先权不可逆——arXiv 时间戳 = “第一个定义  $\beta$  的人” 2. 被引次数 = 议价权——200 次引用 vs 0 次引用，分量完全不同 3. 大厂无法忽略被广泛引用的指标——MMLU 不是 OpenAI 认证的，但所有人都报 4. 定义权—— $\beta$  是唯一递归稳定性指标，后来者要么用、要么解释为什么不用

**引用链冷启动策略:** – 直接邮件推送给相关领域的 20–30 个活跃研究者 – 在 Semantic Scholar / Google Scholar 上追踪引用 – 每获得一个新引用，在 X 上感谢引用者 → 制造社会证明

### 3.2 学术社区播种

**目标社区：** | 社区 | 切入点 | 渠道 | |——|——|——| | AI 评测研究者 | “现有评测全测单次，递归是空白” | OpenReview 讨论、AAAI/NeurIPS workshop | | 合成数据研究 | “你的合成数据管线退化了吗？” | Model Collapse 论文引用链 | | 多智能体系统 | “多轮 agent 递归稳定性” | AgentBench/SWE-bench 社区 | | LLM 安全社区 | “P3 约束对消 = 安全规则在递归中无声失效” | Alignment Forum |

### 3.3 合作引用策略

**DeepSeek 团队：** – 切入点：V3 ( $\beta=0.028$ , 第3名) 和 V4 Flash ( $\beta=0.035$ , 第4名) 表现优秀 – 提案：提供完整数据作为稳定性对比基线 – 策略：如果他们用了你的数据做对比，他们就得引用你

**Google Research：** – 切入点：Gemini 2.5 Flash 是 creative\_writing 瓶颈的**唯一反例**——学术上极有价值 – 问他们：“你们做了什么不一样的事情？”——这个对话本身就制造引用

**Meta AI：** – 切入点：Llama 4 Maverick 比 Llama 3.1 70B 稳定性提升 51%——他们显然做对了什么 – 数据对他们有正面价值

---

## 四、Phase 3：营销战略（第 1–6 个月）

---

### 4.1 核心叙事框架

**一句话主线：**“你的 AI 在第二轮对话时，文采比逻辑先崩。 $\beta$  量化了这件事。”

**三条故事线：**

1. “隐形的退化” —— 单次基准看不出来，递归下才发现
  - “MMLU 拿 90% 的模型，Gen3 时 creative\_writing 退化 40%”
2. “软约束的代价” —— creative\_writing 瓶颈的直觉解释
  - “事实可以查、代码可以跑、逻辑可以验证。但文采不行。所以它第一个崩。”

3. “15 倍差异” —— 最稳定 vs 最不稳定的模型
- “GPT-5.5 和 Claude Opus 4.7 在单次基准上可能差不多，但递归下差了 15 倍”

4.2 社交媒体战术 (X/Twitter)

内容日历：

| 周次   | 内容                            | 格式       |
|------|-------------------------------|----------|
| 第1周  | 发布：16模型β排名 + arXiv链接          | 图表 + 短线程 |
| 第2周  | “creative_writing 是通用瓶颈” 深度解读 | 长线程+ 可视化 |
| 第3周  | “同一模型，同一种子，唯一区别是温度” —— 温度稳健性  | 数据对比     |
| 第4周  | “熵和TTR检测不到这个退化” —— 基线失败       | 对比图      |
| 第5周  | “换了个源模型生成种子，排名还在” —— 跨种验证     | 对比表      |
| 第6周  | “指数还是线性？K=5验证 21/21结果”        | 技术深度     |
| 第7周  | 新模型发布 → 24h内出β                | 快速反应     |
| 第8周+ | 循环：每周一个发现 + 新模型快报             | 持续存在感    |

推文模板（发布周）：

 Introducing StabilityBench: Recursive Stability Index ( $\beta$ )

16 LLMs tested. 15× range in stability.

creative\_writing is the universal bottleneck.

$\beta$  rankings:

1. GPT-5.5 0.011
2. Gemini 2.5 Flash 0.014
3. DeepSeek-V3 0.028
- ...
16. Claude Opus 4.7 0.164

\$0.50 per model. Text-only. Open data.

 [arXiv link]

### 推文模板（发现周）：

Across 13/16 models, creative\_writing is the FIRST constraint to coll

Why? E-II stylistic constraints have no ground truth.

- Facts have externals to check against
- Code has compilers/parsers
- Logic has structure
- Style? Nobody can tell you your prose is "wrong"

Creative writing is naked under recursion.

## 4.3 内容产品化

**$\beta$  排行榜 (GitHub Pages)：** – 静态网站，一张大表 + 交互式排名 – 新模型发布后 24h 内更新 – SEO 优化：每个模型一个独立页面（“GPT-5 stability benchmark”） – 每行：模型 |  $\beta$  | 95% CI | creative\_writing  $\beta$  | 家族 | 等级

**每月  $\beta$  速报 (newsletter 或 blog)：** – 本月新发布模型排名 – 最有趣的 single finding – 与前月对比 – 1-2 段分析

## 4.4 定向渗透

**合成数据管线团队：** – 找到 GitHub 上最活跃的合成数据项目 – 用他们的默认模型跑一份  $\beta$  报告 – 开 issue: “Your pipeline uses Model X which has  $\beta=0.16$  on creative\_writing. At Gen3, the style quality degrades ~40%. Consider Model Y ( $\beta=0.06$ ) for better stability.” – 这不是 spam——这是 actionable data

**Agent 框架：** – LangChain / AutoGPT / CrewAI 的文档或 Discord – 发布一份简短指南: “How to pick a model for multi-turn agents” – 核心建议:  $\beta < 0.07$  for multi-turn,  $\beta < 0.04$  for >10 turns

## 4.5 大厂策略

**不做事：** – 不要试图说服大厂“认可”你的指标 – 不要在没有任何 leverage 的情况下联系他们

**要做的事：** – 在公开讨论中提到  $\beta$  + 大厂模型名 (“Claude Opus 4.7 ranks last in recursive stability”) → SEO 关联 – 让大厂的产品经理被客户问到“你们的  $\beta$  是多少” → 这是唯一会驱动内部行动的力 – 当有 5+ 个外部团队公开讨论  $\beta$  时，大厂会主动找你

## 4.6 内容节奏总览

Month 1: 论文发布 + 社交媒体首轮轰炸 + arXiv 上线

Month 2: 深度解读内容 + 定向推送给研究者 + 合作邮件

Month 3: 排行榜上线 + 新模型快报 + 第一个外部引用

Month 4: 案例研究发布 + agent 框架渗透 + 持续社交媒体

Month 5: 评估进度 + 调整策略 + 第二波内容

Month 6: 回顾 + v2 启动 + 引用链里程碑检查

---



## 五、Phase 4：使用端渗透（第 3–6 个月）

---

### 5.1 三层渗透模型

Layer 1: 学术社区 — 引用 + 论文

Layer 2: 开发者社区 — 工具 + 排行榜 + 指南

Layer 3: 产业用户 — 案例 + proposal + ROI 论证

### 5.2 具体场景

**场景 A：合成数据公司** – 痛点：合成数据质量随代数退化，但不知道多少代后不可用 –  $\beta$  答案：用  $\beta$  选模型 → 确定安全代数上限 – ROI：减少人工筛查成本，提高数据质量

**场景 B：AI 初创公司** – 痛点：选模型做多轮 agent，但单次基准不反映多轮表现 –  $\beta$  答案： $\beta < 0.07$  → 适合多轮； $\beta > 0.12$  → 仅适合单轮 – ROI：减少因模型稳定性差导致的生产事故

**场景 C：企业 AI 采购** – 痛点：采购决策只看 MMLU/HumanEval，上线后发现多轮对话质量骤降 –  $\beta$  答案：在 evaluation card 中加入  $\beta$  – ROI：避免选错模型的沉没成本

### 5.3 Agent 框架集成

- LangChain: 提交 PR 在 Model 文档中添加 `stability_beta` 字段
- AutoGPT: 在 benchmark 页面添加  $\beta$  列
- 各类 agent 框架的 Discord/Slack: 定期发布  $\beta$  更新

---

## 六、Phase 5：v2 升级（第 6+ 个月）

---

- 纯 LLM-judge 提取器替换混合提取器 → 解决非代码域信号问题
- 下游验证完成（标准化任务套件  $n \geq 30$ ）
- K=10 深度扩展
- 人工编写种子集

- 多 GPU 神经验证扩展到 >5 模型
- 多语言扩展（中文优先）

## 七、风险与应对

| 风险              | 概率 | 影响 | 应对                    |
|-----------------|----|----|-----------------------|
| arXiv 账号无法注册    | 中  | 高  | 找合作者代提交或使用 techrxiv   |
| 论文被 desk reject | 低  | 中  | 转投其他预印本平台             |
| 大厂抢先发类似指标       | 低  | 高  | 快速 arXiv → 锁定优先权      |
| 0 引用冷启动失败       | 中  | 中  | 转向内容营销 + 直销           |
| 下游验证被人攻击        | 高  | 中  | 已诚实标注 + P3 神经验证做机制层防御 |
| 提取器被逆向          | 低  | 中  | 种子库闭源是真正的壁垒           |

## 八、当前待办（本周）

| # | 任务                 | 负责人    | 状态                                                                                    |
|---|--------------------|--------|---------------------------------------------------------------------------------------|
| 1 | arXiv 账号注册         | 邓      |  |
| 2 | arXiv 论文提交         | 邓      |  |
| 3 | Zenodo 数据打包        | Claude |  |
| 4 | Zenodo 上传 + 获取 DOI | Claude |  |
| 5 | GitHub 仓库初始化       | Claude | 进行中                                                                                   |

| #  | 任务                   | 负责人             | 状态 |
|----|----------------------|-----------------|----|
| 6  | .gitignore 闭源保护      | Claude          | ✅  |
| 7  | README 编写            | Claude          | 🕒  |
| 8  | 论文插入 DOI             | Claude          | 🕒  |
| 9  | X/Twitter 发布稿        | Claude 起草 + 邓审核 | 🕒  |
| 10 | GitHub → Zenodo 自动关联 | Claude          | 🕒  |

## 九、里程碑

| 时间    | 里程碑        | 验证标准                                   |
|-------|------------|----------------------------------------|
| 第2周   | Phase 1 完成 | arXiv ID + Zenodo DOI + GitHub repo 就绪 |
| 第1个月  | 首次社交媒体传播   | 推文 $\geq$ 5K 曝光 + $\geq$ 100 互动        |
| 第2个月  | 首个外部引用     | Google Scholar 显示 $\geq$ 1 非自引         |
| 第3个月  | 引用链启动      | $\geq$ 5 独立引用 + GitHub $\geq$ 50 stars |
| 第6个月  | 使用端渗透      | $\geq$ 1 外部团队主动使用 $\beta$ 选模型          |
| 第12个月 | 领域认可       | $\geq$ 50 引用 + 至少 2 个大厂模型卡包含 $\beta$   |

本计划书随项目进展持续更新。