

DecayMonitor评测平台框架

DecayMonitor — LLM 递归稳定性评测平台框架

2026-05-12 | 方向确认版

一、一句话定位

在 LLM 评测矩阵中新增”递归稳定性 β ”这个维度。现有评测全部测单次质量，我们测模型在自主循环中能撑多久。

二、 β 是什么

模型递归读取自己输出时，每代丢失的约束质量比例。


math_reasoning: Gen0: 1.000 → Gen1: 0.782 → Gen2: 0.521 → Gen3: 0.338
↓ $\beta=0.31$ /代

β 值	含义	10 代后质量	适用场景
< 0.15	极稳定	~20%	长链 agent
0.15–0.25	较稳定	~5–10%	中等 agent
0.25–0.35	退化明显	~2–5%	短链任务
> 0.35	快速退化	< 1%	不宜 agent

6 个能力维度独立测 β ：数学推理、代码生成、事实知识、逻辑一致、创意写作、通用能力。

三、为什么是我们

竞争格局



- 左上象限（政府+无商业模式）：FlagEval、OpenCompass。评测质量不错，但没动力赚钱。
- 右下象限（商业+无新模式）：SuperCLUE。想商业化但没融到钱、没建起社区。
- 右上象限（商业+有模式）：LMArena。唯一跑通的。500 万 MAU 投票 → \$3000 万 ARR。
- 我们的位置：从右下往右上走。不做第 11 个通用评测，做唯一测递归稳定性的。

中国市场的空白

维度	谁在做	有商业闭环吗
知识	FlagEval, OpenCompass, SuperCLUE, CEval.....	否
推理	同上	否
代码	同上	否
安全	同上 + 监管机构	否
递归稳定性	无人	我们来做

中国没有一个 LMArena。SuperCLUE 最接近但卡在”免费出报告”阶段，没有社区机制、没有商业闭环、没有融资。这是窗口。

四、产品蓝图

免费榜（公信力 = 产品）

DecayMonitor β 排行榜									
排名	模型	β↓	数	码	事	逻	创	通	
1	Qwen2.5-7B	0.2865	●	●	●	●	●	●	
2	Claude Opus 4.6	0.2971	●	●	●	●	●	●	
3	Claude Sonnet	0.3106	●	●	●	●	●	●	
4	Claude Haiku	0.3107	●	●	●	●	●	●	
..	(每周自动更新 10+ 模型)								
模型详情页：6维衰减曲线 · 执行者诊断 · 同族对比									
模型对比：2-4模型 β×6能力并排 · 场景推荐									

对标：Chatbot Arena 的 Elo 排行榜，但我们的数据是全自动生成的，不需要人投票。

付费线（变现）

层级	价格	内容	目标客户
免费	\$0	排行榜 + 模型详情 + 对比	所有人
Pro	\$1,499/次	闭门评测，n=100，深度诊断，不上榜	模型厂商发布前

层级	价格	内容	目标客户
Enterprise	\$4,999/月	每 checkpoint 评测 + 训练数据诊断 + 专属 API	模型训练团队

定价逻辑： LMArena 定制评测报价 \$5,000–50,000。我们 \$1,499 是明显偏低的。初期用低价获客，有案例后回调到 \$2,999–4,999。


不做的

- 不做实时监控 SaaS (`monitor.watch()`)
- 不做 LangChain callback 集成
- 不做私有化部署
- 不碰 agent 框架

原因： 评测是”卖尺子”，监控是”卖安防系统”。尺子市场小但精准——你知道谁会买（模型厂商）。安防市场大但分散——100 万开发者每个付 \$49 跟 10 个模型厂商每个付 \$4,999 的销售成本完全不同。选尺子。

五、算法原理（三步）

第 1 步：文本 → 8 特征（纯规则，CPU only）



第 2 步：8 特征 → S_n（约束质量分）

$\sigma_{\text{syntax}} = 0.65 \times \text{逻辑密度} + 0.35 \times \text{句法CV}$
 $\sigma_{\text{style}} = \text{词汇多样性} \times (1 - 0.5 \times \text{重复} - 0.3 \times \text{截断} - 0.2 \times \text{填充})$
 $\sigma_{\text{fact}} = 0.55 \times \text{大小写规约} + 0.45 \times \text{数字完整性}$
 $\sigma_{\text{coherence}} = 0.55 \times \text{逻辑密度} + 0.45 \times (1 - \text{重复})$
 $\sigma_{\text{safety}} = 0.5$

$S_n = \sum \sigma / 5 \quad \in [0, 1]$


第 3 步：S_n 序列 → β

$$S_n = S_0 \times (1-\beta)^n$$
$$\log(S_n/S_0) = n \times \log(1-\beta)$$

最小二乘线性回归 → 斜率 → β = 1 - e^斜率
6个能力维度各算一个 β → 全局 β = 各维度 β 均值


验证： 纯文本特征 vs LLM judge (Claude) Spearman 相关性： E-I 0.93 / E-II 0.98 / E-III 0.27。
E-III 较弱但权重已降低。

六、技术架构



单模型评测耗时： 12 seeds × 3 gens × 0.5s sleep + API 延迟 ≈ 2 分钟。成本： ~\$0.50/模型 (API 调用费)。

七、工程路线图



Phase A: 统一实验框架 ✅ 已完成

- ✅ provider_adapter.py, experiment_config.py, experiment_runner.py
- ✅ pyproject.toml
- ✅ 删除 3 个临时脚本

Phase B: 科学严谨性 ← 当前 (需 4 周)

任务	条件	费用
n=100 seeds 验证 (4 模型)	API 费用	\$126
P3 严格检验 (逐维 π 分量)	GPU 机器	\$0
DeepSeek-V3/R1 家族 β	API key	\$5
Llama 3 家族 β	Together API	\$10
temperature 稳健性测试	API 费用×3	\$100

总费用 < \$300。唯一瓶颈：GPU。

Phase C: 论文 + 开源 (1-2 个月)

Phase D: 排行榜网站 (1-2 个月)

Phase E: 付费服务运营

八、收入模型

参照系：LMArena 的轨迹

2025.5 种子轮 \$1亿 / 估值 \$6亿
2025.9 推出 B2B "AI Evaluations"
2025.12 \$3000万 ARR (上线仅 4 个月)
2026.1 A轮 \$1.5亿 / 估值 \$17亿

他们的变现路径：免费榜积累公信力 → 模型厂商主动来问”能不能帮我们私下测” → 推出付费评测产品。

我们的预测

节点	免费榜模型数	Pro 客户/月	Enterprise	月收入
上线 (arXiv 后)	4→10	0	0	\$0

节点	免费榜模型数	Pro 客户/月	Enterprise	月收入
3 个月	15	2-3	0	\$3,000-4,500
6 个月	20	5	1	\$12,500
12 个月	30	8	3	\$27,000
24 个月	50	15	8	\$62,500

月运营成本

项目	月费
服务器 + 数据库	\$80
API 评测成本 (30 模型 × \$0.50)	\$15
域名 + CDN	\$20
合计	\$115

6 个月内自负盈亏。这是评测平台相对监控产品的关键优势——不需要大量用户，少量高价值企业客户即可覆盖成本。

九、市场规模估计

客户类型	数量（全球）	可触达比例	年合同额	TAM
LLM 厂商（训练新模型）	~100	30%	\$60,000	\$1.8M
AI agent 初创	~5,000	5%	\$1,500	\$375K
企业 AI 运维	~50,000	0.5%	\$1,500	\$375K
学术/研究机构	~500	20%	\$0（免费）	\$0

保守 TAM：\$2.5M/年。 这不大，但对一个 2-3 人团队来说足够了。LMArena 证明 \$30M ARR 是可能的——但他们覆盖的维度多，我们只做一个维度。做精它。

十、退出策略

三条路，优先级递减：

1. **被 LMArena/HuggingFace 收购：**最可能。他们缺”递归稳定性”维度，我们有理论和数据。价格参照：LMArena \$17 亿估值下的小型收购 → \$5-20M
2. **独立运营 → 小团队生存：**月收入 \$50k+，养 2-3 人。不用融资，不需要高增长
3. **融资做大：**如果市场反响超预期，走 LMArena 的路——种子轮 → 扩覆盖 → A 轮

十一、当前待办

本周立刻可做的事：

优先级	任务	需要
P0	获取 DeepSeek API key，跑第三个家族 β	注册 platform.deepseek.com
P0	确认 GPU 可用，准备 P3 严格检验	Window-1 机器
P1	n=100 seeds 实验（先跑一个模型验证）	\$15 API 费用
P2	获取 Together AI key，跑 Llama 家族	注册 together.ai

阻而不能动的事： GPU 不可用则不启动 P3（论文硬伤）。其余全部可以并行。