

DecayMonitor评测平台框架v3

DecayMonitor — LLM 递归稳定性评测平台 v3

2026-05-12 | 深度展开版

第一章：平台定位与运行框架


1.1 我们做什么

在 LLM 评测矩阵中新增”递归稳定性 β ”维度。

现有所有评测——MMLU（知识）、HumanEval（代码）、Chatbot Arena（人类偏好）、HELM（多维度）——测的都是单次输入→输出的质量。没有人测模型在自主循环中的退化速率。

AI agent（AutoGPT、CrewAI、Devin）跑一个任务需要 10–50 次模型调用，每次调用都会读到前一轮的输出。这就是递归生成。 β 测的就是模型在这种递归场景下每代丢失多少约束质量。

1.2 平台运行全景



1.3 评测模型覆盖计划

Phase 1: 上线时（已有数据）

模型	家族	β	状态
Qwen2.5-7B-Instruct	Qwen	0.2865	✔
Claude Opus 4.6	Claude	0.2971	✔
Claude Sonnet 4.6	Claude	0.3106	✔
Claude Haiku 4.5	Claude	0.3107	✔

Phase 2: 1 个月内扩展至 10+ 模型

模型	家族	优先级	获取方式
DeepSeek-V3	DeepSeek	P0	platform.deepseek.com
DeepSeek-R1	DeepSeek	P0	同上
GPT-4o	OpenAI	P1	OpenAI API
GPT-4.1	OpenAI	P1	OpenAI API
Llama 3 70B	Meta	P1	Together AI
Gemini 2.5 Pro	Google	P1	Google AI API
Mistral Large	Mistral	P2	Mistral API
o3-mini	OpenAI	P2	OpenAI API

Phase 3: 3 个月内 20+ 模型持续更新

- 每周一自动重测所有模型
- 新模型发布 48h 内上线 β 数据
- 建立 β 历史曲线（追踪迭代对稳定性的影响）

1.4 排行榜设计

首页 β 总榜：

排名	模型	$\beta\downarrow$	数	码	事	逻	创	通
1	Qwen2.5-7B	0.29	0.28	0.27	0.18	0.33	0.25	0.29
2	Claude Opus	0.30	0.30	0.25	0.11	0.28	0.42	0.30
3	DeepSeek-V3	0.31	—	—	—	—	—	—
4	Claude Sonnet	0.31	0.27	0.27	0.17	0.29	0.33	0.31
5	Claude Haiku	0.31	0.38	0.20	0.19	0.35	0.25	0.31
6	GPT-4o	0.34	—	—	—	—	—	—
...								

颜色：● <0.20 ● <0.30 ● <0.35 ● >0.35
 β 越低越好。全局 β = 6 维度均值。N/A = 未完成该维度评测。

模型详情页包含： – 6 维 β 衰减曲线（交互式 ECharts） – S_n 跨代变化轨迹
（Gen0→Gen1→Gen2→Gen3） – 执行者退化诊断：E-I/E-II/E-III 分类 + 严重度 – 同家族模型对比
– 原始 JSONL 数据下载

第二章：核心算法详解

2.1 算法总览

输入：12 个种子文本 (Gen0) $\times$ 3 代递归生成 (Gen1-3)

↓

步骤1：文本特征提取 (CPU only, 纯规则)

 每个样本 $\rightarrow$ 8 个统计特征

↓

步骤2：特征 $\rightarrow$ 约束状态 S_n

 8 特征 $\rightarrow$ 5 维 $\sigma \rightarrow S_n$

↓

步骤3： S_n 序列 $\rightarrow \beta$ 拟合

 最小二乘对数线性回归

↓

输出： β (全局) + β_{math} , β_{code} , β_{fact} , β_{logic} , β_{creative} , β_{general}

 + 执行者退化诊断 (E-I/E-II/E-III)

2.2 步骤 1：文本特征提取

设计原则：零模型依赖，纯文本表面统计量。所有特征在 [0, 1] 范围，高值 = 好。

E-I 公理级 (逻辑/推理链完整性):

特征 1: ei_logic_density

计算: $\text{count}(\text{token} \in \text{LOGIC_CONNECTORS}) / n_{\text{tokens}}$

LOGIC_CONNECTORS (英文 35+):

therefore, because, thus, hence, consequently, moreover, furthermore, nevertheless, otherwise, whereas, although, unless, accordingly, meanwhile, since, then, so, if, but, and, or, ...

LOGIC_CONNECTORS (中文 15+):

因此, 所以, 然而, 因为, 从而, 于是, 故, 则, 但是, 不过, 此外, 同时, 尽管, 除非, 否则

退化信号: 逻辑连接词密度下降 $\rightarrow$ 推理链断裂

LLM judge Spearman $\rho = 0.93$

特征 2: ei_syntax_cv

计算: $\text{std}(\text{句子token数}) / \text{mean}(\text{句子token数})$

分句规则: 按 [.!?.! ? \n] 分割, 取 > 3 tokens 的句子

退化信号: CV 上升 $\rightarrow$ 句子结构崩坏 (有的极短、有的极长)

与 LLM judge 的综合相关性: 包含在 0.93 的 E-I 整体相关中

E-II 标度级（风格/表达多样性）：

特征 3: eii_bigram_repetition

计算: $\text{count}(\text{重复出现的相邻词对}) / (\text{total_bigrams} + 1)$

Bigram 定义: 连续两个 token 组成的对

"the cat sat the cat" → bigrams: (the,cat), (cat,sat), (sat,the), (the,cat)
→ (the,cat) 重复 → $1/4 = 0.25$

退化信号: 重复率上升 → 车轱辘话

注意: Claude 家族文本天然缺乏 bigram 重复, 此特征在该家族效力有限。

通过 unique_word_ratio + filler_ratio 组合弥补。

LLM judge Spearman $\rho = 0.98$ (E-II 整体, 非单特征)

特征 4: eii_unique_word_ratio

计算: $\text{len}(\text{set}(\text{words})) / \text{len}(\text{words})$

退化信号: 词汇多样性下降 → 表达的丰富度坍缩

在 Claude 家族中是最有效的 E-II 信号 (unique_word_ratio 跨代单调递减)

特征 5: eii_filler_ratio

计算: $\text{count}(w \in \text{FILLER_WORDS}) / n_words$

FILLER_WORDS = {the, a, is, of, it, in, this, that, for, with, on, as, at, by}

退化信号: 填充词占比上升 → 表达越来越"水"

特征 6: eii_truncation_ratio

计算: $\text{count}(\text{len}(w) > 7 \text{ 且被截断}) / \text{count}(\text{len}(w) > 7)$

"截断"定义: 词不是完整词汇 (不在词典中) 且长度 < 原始词长度

退化信号: 长词被截断 → 输出不完整

实际实验中此特征在 API 模型上很少触发 (模型输出完整度高)

E-III 边界级（事实/格式规约）：

特征 7: eiii_proper_case_ratio

英文: $\text{count}(\text{首字母大写词}) / n_words$

中文: 专名标注率 (人名/地名/机构名的正确标注比例)

退化信号: 大小写/标注规约丢失 → 边界标记退化

LLM judge Spearman $\rho = 0.27$ (E-III 整体, 最弱)

特征 8: eiii_number_integrity

计算: $\text{count}(\text{保持原样的数字实例}) / \text{count}(\text{总数字实例})$

数字实例判断:

- "2020年" 在上下文中数字不变 → intact
- "1000" 变成 "大约1000" → 模糊化, 计为 partial
- "1776" 变成 "1770" → 篡改, 计为 lost

退化信号：数字被四舍五入或篡改 → 事实精度丢失

自适应分块机制：

Goldilocks 区：80-200 tokens

```
if n_tokens > 300:
    文本 → 按句子边界切片 → 每块 80-200 tokens
    → 逐块提取特征 → 取均值
else:
    直接提取特征
```

目的：避免长文本特征饱和（逻辑词密度在 500 token 文本中自然稀释）

语言自动检测：

中文字符占比 > 30% → 中文模式（使用中文连接词库 + 字符级分词）
否则 → 英文模式（使用英文连接词库 + 空格分词）

2.3 步骤 2：特征 → 约束状态

5 维约束 σ 的定义：

σ	含义	主要来源特征
σ_{fact}	事实一致性	E-III: proper_case, number_integrity
σ_{syntax}	结构完整性	E-I: logic_density, syntax_cv
σ_{style}	风格稳定性	E-II: unique_ratio, bigram_rep, filler, trunc
σ_{safety}	安全对齐	中性 (0.5), 合成文本无安全维度
$\sigma_{coherence}$	逻辑连贯	E-I logic + (1-E-II bigram_rep)

加权映射公式：

$\sigma_{syntax} = 0.65 \times ei_logic_density + 0.35 \times ei_syntax_cv$

$\sigma_{style} = unique_word_ratio \times (1 - 0.5 \times bigram_rep - 0.3 \times trunc - 0.2 \times filler)$

$\sigma_{fact} = 0.55 \times proper_case_ratio + 0.45 \times number_integrity$

$\sigma_{coherence} = 0.55 \times ei_logic_density + 0.45 \times (1 - bigram_rep)$

$\sigma_{safety} = 0.5$

$S_n = (\sigma_{fact} + \sigma_{syntax} + \sigma_{style} + \sigma_{safety} + \sigma_{coherence}) / 5$

权重校准来源：

维度	与 LLM judge Spearman ρ	权重策略
E-I ($\sigma_{syntax} + \sigma_{coherence}$ 的一部分)	0.93	高权重, 0.65/0.35 偏向逻辑密度
E-II ($\sigma_{style} + \sigma_{coherence}$ 的一部分)	0.98	高权重, unique_word_ratio 为主信号

维度	与 LLM judge Spearman ρ	权重策略
E-III (σ_{fact})	0.27	降权。如 LLM judge 可用则替换 σ_{fact}
σ_{safety}	N/A	固定 0.5，合成文本无安全退化

关键设计决策：E-III 弱信号处理。 事实一致性的纯文本信号弱 ($\rho=0.27$)。但这不是算法缺陷——事实检测本质需要外部知识。我们的处理：

- 在标准模式（无 LLM judge）中，E-III 权重在 S_n 中仅占 20% (1/5)，不主导最终分数
- 在深度模式（Pro/Enterprise）中，可选接入 LLM judge 替换 σ_{fact}
- 这确保了标准评测的稳定性—— β 主要由 E-I+E-II 驱动，这两个维度的信号强且可靠

2.4 步骤 3: β 拟合

数学模型：

约束质量随代数指数衰减：

$$S_n = S_0 \times (1 - \beta)^n$$

其中 $S_0 \equiv 1.0$ （Gen0 人类种子文本的约束基线）。注意实验验证了 $S_0=1.0$ 的合理性：Gen0 文本是人类编写的、约束完整的种子，没有退化。

对数线性化：

$$\begin{aligned} S_n / S_0 &= (1 - \beta)^n \\ \log(S_n / S_0) &= n \times \log(1 - \beta) \end{aligned}$$

$$\text{令 } y_n = \log(S_n / S_0)$$

$$\text{令 } k = \log(1 - \beta)$$

$$\text{则 } y_n = k \times n \quad (\text{过原点线性关系})$$

最小二乘估计：

给定数据点：($n=1, y_1$)，($n=2, y_2$)，($n=3, y_3$)

$$\hat{k} = \Sigma(n_i \times y_i) / \Sigma(n_i^2) \quad (\text{过原点回归})$$

$$\hat{\beta} = 1 - \exp(\hat{k})$$

钳制规则：

$$\begin{aligned} \text{if } \hat{\beta} < 0.03: & \beta = 0.03 \quad (\text{低于此值为噪声}) \\ \text{if } \hat{\beta} > 0.55: & \beta = 0.55 \quad (\text{高于此值意味着 3 代内完全坍缩, 实际罕见}) \\ \text{else:} & \beta = \hat{\beta} \end{aligned}$$

6 能力维度独立拟合：

每个能力维度（`math_reasoning` / `code_generation` / `factual_knowledge` / `logical_consistency` / `creative_writing` / `general`）有 2 个种子，独立追踪跨代 $S_n \rightarrow$ 独立拟合 β 。

全局 β ：

```
β_global = mean(β_math, β_code, β_fact, β_logic, β_creative, β_general)
```

2.5 执行者退化诊断

诊断逻辑 (executor_classifier.py):

对每个能力维度, 分析跨代 σ 变化模式, 判断退化主要由哪种执行者失效驱动:

输入: 跨代 σ_fact, σ_syntax, σ_style 序列 + 文本特征序列

```
规则:
if σ_syntax_drop_rate > σ_style_drop_rate
  AND ei_logic_density_drop > 0.15:
  → 诊断: E-I_loss (逻辑断裂)
  → 干预: 增强 chain-of-thought 提示

if σ_style_drop_rate > σ_syntax_drop_rate
  AND eii_unique_word_ratio_drop > 0.10:
  → 诊断: E-II_loss (风格坍缩)
  → 干预: 提高 temperature 或换模型

if σ_fact_drop_rate is dominant
  AND eiii_number_integrity_drop > 0.10:
  → 诊断: E-III_loss (事实侵蚀)
  → 干预: 加强输出格式约束

else:
  → 诊断: mixed (混合退化)
```

严重度评分:

```
severity = mean(σ_drop_rate) × (predicted_collapse_gen_reciprocal)
          = mean(Δσ/σ_prev) × (1 / predicted_collapse_gen)
```

值域: [0, 1]
< 0.3: 轻度
0.3-0.6: 中度
> 0.6: 重度

2.6 算法验证数据

以下是已有数据 (4 模型 × 12 seeds × 3 gens = 48 样本/模型) 的关键指标:

β 跨模型一致性:

模型	β	家族
Qwen2.5-7B	0.2865	Qwen
Opus 4.6	0.2971	Claude
Sonnet 4.6	0.3106	Claude
Haiku 4.5	0.3107	Claude


Claude 家族 β 范围 0.0136 < 0.02 阈值 → β 是家族常数。

与 LLM judge 的特征相关性 (Spearman ρ):

维度	ρ
E-I (逻辑/推理)	0.93
E-II (风格/表达)	0.98
E-III (事实/边界)	0.27

第三章：竞争壁垒分析

3.1 壁垒总览




3.2 壁垒一： β 定义权与理论体系

为什么难复制：

β 不是一个随便定义的指标。它背后是约束吸引子坍缩理论——一套有因果解释、有可验证预测 (P1–P4) 的理论框架。别人可以写一个类似的评测脚本，但拿不出”为什么 β 是这样的”因果解释。

理论链条：



持久性： 长期。理论 + 论文的学术壁垒不同于工程壁垒——不会被”重写一遍代码”绕过。

3.3 壁垒二：CPU-only 低成本评测

为什么重要：

	我们的方法	需要 GPU 的方法
单模型评测成本	~\$0.50（API 费用）	\$0.50 + GPU 时间
可评测的模型	所有（包括闭源 API）	仅开源模型
每周扫 30 个模型	\$15	\$15 + GPU 集群
冷启动条件	API key	GPU 集群

为什么难复制： 不是”纯文本特征提取”这个思路难复制——而是我们在 4 个模型上校准过的特征权重（0.65/0.35 等）和与 LLM judge 的 Spearman 验证数据。别人可以从头做，但需要跑同样的校准实验、获得同样的相关性水平。这是时间和数据壁垒，不是算法壁垒。

3.4 壁垒三：跨家族 β 数据库

先发优势：

一旦我们发布第一个跨 4+ 家族的 β 数据库，后来者即使用同样的方法跑出数据，也只是在”复现”我们的发现。学术界和产业界的引用链会指向第一个发表者。

数据护城河的自我强化： – 每新增一个模型家族，数据库价值增加（不是线性，是网络效应——跨家族对比的组合数 = $C(n, 2)$ ）– 时间序列数据（每月 β 变化）积累 → 别人无法回到过去补数据 – 新模型发布 48h 内出 β → 时效性壁垒

3.5 壁垒四：独立第三方信任

最核心的壁垒，也最难建立和维持。

现有评测平台的利益冲突：

平台	收入来源	利益冲突
LMarena	模型厂商付费评测	既当裁判又收参赛者钱
Scale AI SEAL	企业合同	大客户可能影响评测优先级
HuggingFace	企业 Hub 订阅	不直接评测但托管模型

我们的立场： – 排行榜上的模型排序完全独立，不收模型厂商赞助 – Pro/Enterprise 是评测服务费——你付钱我帮你私下测，不影响公开榜排名 – 在网站上公示：排名方法学 + 原始数据可下载 + 复现指南

为什么这是壁垒： 独立第三方信任需要时间积累。一次利益冲突事件就能毁掉。LMarena 已经因为”收 OpenAI 的钱又给 OpenAI 排名”被质疑。我们不拿模型厂商一分钱赞助——这是结构性的信任优势。

3.6 壁垒五：多 Provider 抽象层

技术壁垒最低但最实用：

新增一个模型只需要在 ProviderAdapter 中加一个 provider 配置：

```
# DeepSeek 接入示例
"deepseek": ProviderConfig(
    base_url="https://api.deepseek.com/v1",
    api_key=os.environ["DEEPSEEK_API_KEY"],
    model="deepseek-chat",
)
```

这让我们在“新模型发布后最快出 β ”的竞争中处于优势。不是护城河——是速度优势。

3.7 壁垒综合评估

壁垒	强度	持续时间	被攻破需要
β 定义权 + 理论	★★★★★	10 年+	新的更强理论取代
独立第三方信任	★★★★★	持续积累	一次丑闻
跨家族 β 数据库	★★★★★	3-5 年	从头积累 2+ 年数据
CPU-only 校准权重	★★★	1-2 年	复现我们的校准实验
多 Provider 抽象	★★	6-12 月	写一个适配层

真正的护城河不是技术——是信任 + 数据 + 理论的三位一体。技术可以被复制，但一个被社区信任的品牌、一个积累了 2 年的跨家族 β 数据库、一套被学术界引用的理论——这三样东西加在一起，竞争对手花 10 倍的钱也买不到。

第四章：详细工程计划

Phase A：统一实验框架  已完成（2026-05-12）

产出： - [x] provider_adapter.py — 多后端抽象（QuickRouter/OpenAI/Together/Local） - [x] experiment_config.py — 可复现配置（6 预设 + JSON 持久化） - [x] experiment_runner.py — 全流程自动化（生成→分析→诊断→报告→对比） - [x] pyproject.toml - [x] 删除 3 个临时生成脚本

Phase B：科学严谨性补足（4 周）

这是论文的前提条件。没有这一步，arXiv 审稿人会直接挑出统计缺陷。

B1: n=100 seeds 统计验证（Week 1-2）

子任务	说明	费用
4 模型 × 100 seeds × 3 gens	验证 $n=12$ 的 β 在 $n=100$ 是否稳健	\$126
Bootstrap 95% CI	$\beta \pm 1.96 \times SE$, 每个能力维度	—
$n=12$ vs $n=100$ 一致性检验	两者 β 偏差 < 0.03	—

风险： 如果 $n=100$ 的 β 与 $n=12$ 偏差 $> 0.03 \rightarrow$ 需要重新校准。概率中等，但这正是做 $n=100$ 的原因。

B2: P3 严格检验 (Week 1–3)

子任务	说明
窗口 1 GPU 管线	对每个样本提取 5 维 π 分量 (hidden state 层面)
cos 相似度计算	$\cos(\pi_{g0}, \pi_{g1}), \cos(\pi_{g0}, \pi_{g2}), \cos(\pi_{g0}, \pi_{g3})$
逐维分解	每个 σ 维度的坍塌速率是否一致
P3 统计检验	H_0 : cos 不随代数增加 vs H_1 : cos 随代数增加

这是 P1–P4 四个预测中唯一未严格验证的。代理测试（文本特征层面 $p<0.0001$ ）已通过，但需要 GPU 的 hidden state 层面的证据才够格放进论文。

B3: 第三、四模型家族 (Week 2–3)

子任务	模型	API	费用
DeepSeek–V3	deepseek–chat	platform.deepseek.com	~\$5
DeepSeek–R1	deepseek–reasoner	同上	~\$5
Llama 3 70B	meta–llama/Llama–3–70b	Together AI	~\$10

关键检验： DeepSeek 的 β 如果在 0.28–0.32 之间 $\rightarrow$ 家族常数假说进一步增强。如果 $\beta=0.15$ 或 $\beta=0.45 \rightarrow$ 假说需要修正，但数据本身仍然有发表价值。

B4: Temperature 稳健性 (Week 3–4)

temperature	Sonnet	说明
0.0	?	确定性输出, β 会更低?
0.5	?	中间档
0.8	0.3106 	已完成
1.0	?	高随机性, β 可能更高

假设： β 随 temperature 单调递增（更高的随机性 $\rightarrow$ 更快的约束退化）。但如果 β 对 temperature 不敏感，这反而是更强的发现——说明 β 是模型固有属性，不是采样噪声。

Phase C: 论文 + 开源 (1–2 个月)

C1: 论文写作与提交 (Week 1-4)

目标期刊/会议： arXiv 预印本 → ACL Rolling Review 或 NeurIPS workshop

论文结构： 1. Introduction: LLM 递归生成的退化现象 2. 约束吸引子坍缩理论 ($L_2 \rightarrow C_{div} \rightarrow \beta$) 3. 实验设计 (12→100 seeds, 4 家族, 3 temperature) 4. 结果： β 家族常数、 C_{div} 坍缩验证、P1-P4 检验 5. 纯文本特征方法 (与 LLM judge 的 Spearman 验证) 6. Discussion: β 作为评测新维度的意义

C2: GitHub 开源 (Week 3-4)

- 完整代码库 (MIT 许可)
- 4 模型 β 数据 (JSONL + JSON)
- 复现指南 (README + 一行命令跑实验)
- HuggingFace Space demo

Phase D: 排行榜网站 (论文提交后 1-2 个月)

D1: 网站 MVP (4 周)

周	任务
W1	FastAPI 骨架 + DB schema + 评测引擎对接
W2	React 排行榜首页 + 模型详情页 + ECharts 图表
W3	模型对比页 + GitHub OAuth 认证
W4	Celery 定时评测 + 部署上线

D2: 付费功能 (4 周)

周	任务
W1	Pro 评测流程 + PDF 报告生成
W2	Stripe 集成 + 订阅权限控制
W3	Enterprise dashboard + β 历史追踪
W4	测试 + 安全审计 + 灰度上线

Phase E: 运营与增长 (持续)

- 新模型发布 48h 内出 β (Twitter/X + Reddit 分发)
- 每周博客： β 排行榜变化解读
- 季度 β 趋势报告 (免费 PDF, 邮件列表引流)
- 联系模型厂商 eval 团队 (Anthropic/DeepSeek/01.AI)

第五章： 商业模式

5.1 收入模型

	Free	Pro	Enterprise
价格	\$0	\$1,499/次	\$4,999/月
seeds × gens	12 × 3	100 × 5	自定义
结果公开	上榜	闭门	闭门
执行者诊断	基本	深度	深度+干预建议
API 访问	50次/天	包含	无限
历史追踪	—	—	✓
训练数据诊断	—	—	✓
交付物	—	PDF+CSV/JSONL	PDF+API+Slack

定价参照： LMArena 定制评测 \$5,000–50,000/次。\$1,499 是初期获客价。

5.2 收入预测

时间	Pro/月	Enterprise	月收入
M1–3	0	0	\$0
M4–6	2	0	\$3,000
M7–9	4	1	\$11,000
M10–12	7	2	\$20,500
M19–24	15	6	\$52,500

月运营成本：\$140。 1 个 Pro 客户即可盈亏平衡。

第六章： 风险与应对

风险	概率	影响	应对
β 在 n=100 不稳健	中	高	Phase B 优先做。结果不好不投论文
P3 严格检验不通过	低	高	代理测试已通过，且理论预测明确。如不通过则修正理论再投
DeepSeek β 偏离预期	中	中	不管结果都有发表价值
模型厂商不付费	中	中	海外先打（LMArena 已验证付费意愿），中国次之
大公司自己做	高	低	他们只测自己，跨模型视角不可替代

风险	概率	影响	应对
竞品出现	中	中	论文+开源建立 6 个月先发窗口
纯文本特征被质疑	低	中	论文公布与 LLM judge 的 Spearman 对比

第七章：当前行动清单

本周可立即启动（零外部依赖）：

#	行动	预计时间	费用
1	注册 DeepSeek API → 跑第一个 β 实验	2 小时	\$5
2	注册 Together AI → 跑 Llama β 实验	1 小时	\$10
3	改 ExperimentRunner 支持 n=100 seeds	30 分钟	\$0
4	跑 Claude Sonnet n=100 验证	后台运行	\$15

需要协调的：

#	行动	依赖
5	P3 严格检验 GPU 机器 + 窗口 1 管线可用	
6	论文初稿	B1–B4 数据收集完成后