

Synthetic Decay Monitor 产品报告

Synthetic Decay Monitor — 产品化全景报告

日期：2026-05-12 状态：Phase A 完成，Phase B 待启动

一、这是什么

一个 LLM “递归稳定性”评估系统。现有所有 LLM 评测（MMLU、HumanEval、Chatbot Arena）只测单次输出质量——没有人在测模型在自主循环中能撑多久。我们填补这个空白。

核心指标： β （衰减率）——模型递归生成时，约束质量每代丢失的速率。 β 越高，模型在 agent loop 中退化越快。

二、已发现的事实

跨 4 个模型家族的递归生成实验（12 seeds $\times$ 3 代）：

模型	β	家族
Qwen2.5-7B	0.2865	Qwen
Claude Opus 4.6	0.2971	Claude
Claude Sonnet 4.6	0.3106	Claude
Claude Haiku 4.5	0.3107	Claude

关键发现： – $\beta \sim 0.30$ 跨 4 模型高度一致， β 是模型家族常数（Claude 家族范围 $0.0136 < 0.02$ 阈值，PASS） – 约束吸引子坍缩：均值 $\| \Pi \|$ 稳定，但方差 C_{div} 每代坍缩 $4.5\times$ ($\lambda_C = 0.2973/gen$) – 三种执行者退化模式：E-I（逻辑断裂， $\alpha=0.40$ ）、E-II（风格均质化， $\alpha=0.20$ ）、E-III（事实侵蚀， $\alpha=0.08$ ） – 纯文本特征提取可达 75% 准确率，无需 GPU

三、当前成熟度

维度	评分	说明
理论	8/10	约束吸引子坍缩理论完整，P1-P4 可验证预测，R15 修正了框架优先于数据的错误
实验	6/10	4 模型 β 数据一致，P1-P2 验证通过，P3 仅代理测试（需 GPU 严格检验）

维度	评分	说明
代码	6/10	Phase A 完成，ExperimentRunner 统一框架可用，ProviderAdapter 多后端抽象就绪
可复现	5/10	ExperimentConfig JSON 持久化，但历史数据分散在 3+ 目录
对外可用	1/10	无 pip install，无文档，无在线 demo

四、产品路线图

Phase A：统一实验框架 （2026-05-12 完成）

产出： - provider_adapter.py — 统一 API 后端（QuickRouter/OpenAI/本地），告别硬编码 API key
- experiment_config.py — 可复现实验配置，6 个预设，JSON 持久化 - experiment_runner.py — 一条命令跑完整实验：生成→分析→诊断→报告→跨模型对比 - pyproject.toml — 项目配置 - 删除 3 个临时脚本，功能全部整合

用法：

```
python -m synthetic_decay_monitor.experiment_runner --preset opus
python -m synthetic_decay_monitor.experiment_runner --model claude-sonnet-4-6 --provider quickrouter --compare haiku_lineage.jsonl opus_lineage.jsonl
```

Phase B：数据层加固（预计 2 周）← 下一步

- 统一数据目录，集中 3 处分散的实验数据
- RealLineageDataset 标准化加载/验证/导出
- provider_adapter 增加成本追踪（token 用量 → \$ 累计）
- 单元测试 65 → 100+，覆盖 $\beta=0$ 、S_n NaN、空 lineage 等边界条件

Phase C：P3 严格检验 + 第三方模型家族（预计 4 周）

- 窗口 1 GPU 产出逐维 π 分量 → P3 严格检验（这是论文最关键的缺失数据）
- DeepSeek-V3/R1 实验（第三个模型家族，检验 β 家族常数假说）
- Llama 3 实验（第四个模型家族）
- 不同 temperature (0.0/0.5/1.0) 下 β 稳健性
- n=100 seeds 统计稳定性验证
- 产出：arXiv 论文核心数据

Phase D：SaaS API（预计 6 周）

- FastAPI 后端（已有 server.py 基础）
- 异步任务队列（Celery + Redis）

- 用户管理 + API key + 用量统计
- Stripe 支付集成
- React 前端仪表盘（交互式 β 对比图）

Phase E：监控集成（预计 6 周）

- `pip install decay-monitor` → `monitor.watch(model_output)` 实时 `C_div`
- LangChain callback: agent loop 中自动退化检测
- Webhook 告警: `C_div` 低于阈值 → Slack/email 通知
- 自动切换: 退化检测 → 切换到备选模型

五、商业模式

价值主张

现有 LLM 评测告诉你模型”答对多少题”。我们告诉你模型”在自主循环中能撑多久”。

这对于 AI agent 开发者是刚需——选模型不能只看 benchmark 分数，要看它在自主循环中的稳定性。

目标客户

层级	客户	痛点	产品
1	AI agent 初创公司	agent loop 中输出越来越差，不知道为什么	SaaS API + SDK
2	LLM 训练团队	不知道训练数据在哪个能力维度缺自我纠错	训练诊断报告
3	企业 AI 运维	agent 静默退化，发现时已影响用户	私有部署 + 实时告警
4	投资/研究机构	需要”模型稳定性”的客观量化指标	β 排行榜

定价策略

方案	月费	内容
Free	\$0	开源 pip install, $n \leq 12$ seeds
Pro	\$49	API 100次/月, $n \leq 100$, 全模型对比
Team	\$199	无限 API, 私有模型评测, 团队协作
Enterprise	\$2000+	私有化部署, SLA 保障, 训练诊断报告

收入预测

时间节点	用户规模	月经常性收入
6 个月	0 (纯研究阶段)	\$0
12 个月	50-100 付费开发者	\$5-10k
24 个月	10-20 企业 + 500+ 个人	\$50-100k

六、营销策略

三条路径并行

学术路径（建立权威） 1. arXiv 论文发表 ($\beta \sim 0.30$ 跨 4 模型 + 约束吸引子坍塌理论) 2. GitHub 开源全部代码 + 实验数据 3. NeurIPS/ACL workshop 投稿 4. 直接联系 Anthropic、DeepSeek、Meta 的 evaluation 团队

内容路径（建立认知） 1. 创建 decaymonitor.ai，每周自动评测发布 **β 排行榜** 2. 技术博客：“你的 AI agent 在悄悄变蠢——这是证据” 3. 对比文章：“MMLU 第一的模型 $\neq$ agent 开发的最佳选择” 4. 案例研究：用 β 分析 AutoGPT/Devin 的模型选型

社区路径（建立用户群） 1. 给 LangChain / AutoGPT 提交集成 PR——开发者自然看到 2. HuggingFace Space 在线 demo——粘贴文本 $\rightarrow$ 即时诊断报告 3. 每次新模型发布 (GPT-5、Claude 5、Llama 4)，第一时间出 β 对比

关键里程碑

时间	里程碑	可量化指标
3 个月	arXiv + GitHub 开源	GitHub stars >500, 学术引用 >10
6 个月	HuggingFace Space + β 排行榜上线	月活跃用户 >1000
12 个月	SaaS API 正式上线	付费用户 >50
18 个月	首个企业客户签约	年合同额 >\$10k
24 个月	成为 LLM 评测标准维度之一	行业认可

七、风险与缓解

风险	概率	影响	缓解措施
$\beta \sim 0.30$ 在 $n=100$ seeds 下不成立	中	高	Phase C 优先做 $n=100$ 统计验证
第三方模型 β 不遵循家族常数假说	中	中	不管结果如何，数据本身有发表价值
大模型公司自己做类似评测	高	中	开源 + 跨模型视角是 moat，他们只能测自己
市场根本不需要”递归稳定性”指标	低	高	先 HuggingFace Space 验证需求，再建 SaaS

风险	概率	影响	缓解措施
QuickRouter API 不稳定或涨价	中	中	ProviderAdapter 已支持多后端切换

八、立即可做的事

- 1. **Phase B 启动** — 统一数据目录，集中 experiment_data/、shared/、paper/experiment_data/ 三处数据
- 2. **provider_adapter 成本追踪** — 每次 API 调用记录 token 用量和 \$ 成本
- 3. **Phase C 准备** — 获取 DeepSeek API key，准备第三方模型家族实验
- 4. **arXiv 论文大纲** — 趁实验数据新鲜，开始写论文框架