

DecayMonitor — LLM 递归稳定性评测平台方案

DecayMonitor — LLM 递归稳定性评测平台方案

版本： v1.0 / 2026-05-12 定位： 评测 LLM 在自主循环中”能撑多久”的独立第三方平台

一、产品概述

1.1 现有 LLM 评测的盲区

当前所有主流评测体系——MMLU（知识）、HumanEval（代码）、Chatbot Arena（人类偏好）、HELM（多维度）——测的都是**单次输入→输出的质量**。

但真实世界的 AI agent 不是单次调用。一个 AutoGPT 任务需要 10–50 次模型调用，每次调用会读到自己前一轮的输出。模型在**递归读取自己的输出时会退化**，而这个退化速度，现有所有评测都看不到。

1.2 我们的定位

DecayMonitor 是在 LLM 评测矩阵中新增一个维度：递归稳定性（Recursive Stability）。

评测体系	测什么	怎么测
MMLU	知识覆盖	单选题正确率
HumanEval	代码生成	单次生成通过率
Chatbot Arena	人类偏好	众包投票 ELO
HELM	多维度	42 个场景 + 7 个指标
DecayMonitor	递归稳定性 β 衰减率	$\times 6$ 能力维度

1.3 核心指标： β （衰减率）

β = 模型在递归生成中，每代丢失的约束质量比例。

- $\beta = 0.10$: 10 代后保留 $0.9^{10} \approx 35\%$ 质量 → 稳定型
- $\beta = 0.31$: 10 代后保留 $0.69^{10} \approx 2\%$ 质量 → 退化型
- $\beta = 0.50$: 3 代后已无法使用 → 不适合任何 agent 场景

β 可以直接回答 benchmark 回答不了的问题：“这个模型在我的 agent loop 里能撑几轮。”

跨能力维度分解： 同一个模型，math_reasoning $\beta=0.40$ （退化快），factual_knowledge $\beta=0.08$ （退化慢）。这意味着训练数据在数学领域缺乏自我纠错样本——这对模型训练团队是 actionable insight。

二、算法原理

整个评测管线分为三步。全部在 CPU 上完成，不需要 GPU。

2.1 文本特征提取（纯规则，零依赖）

对每个样本提取 8 个表面统计特征，按执行者类型分为三组：

E-I 公理级（逻辑/推理链）：

特征	计算方式	退化信号
ei_logic_density	逻辑连接词出现次数 / 总 token 数	推理链断裂时下降
ei_syntax_cv	句子长度变异系数（std/mean）	句子结构崩坏时升高

逻辑连接词库内置 35+ 英文（therefore/because/thus/hence/nevertheless.....）+ 15+ 中文（因此/所以/然而/从而/故/则.....）。

E-II 标度级（风格/表达）：

特征	计算方式	退化信号
eii_bigram_repetition	重复 bigram 数 / (总 bigram 数 + 1)	车轱辘话增多时上升
eii_unique_word_ratio	唯一词数 / 总词数	词汇多样性下降时下降
eii_filler_ratio	高频填充词（the/a/is/of/this/.....）占比	废话比例升高时上升
eii_truncation_ratio	被截断的长词（>7 字符）比例	输出不完整时升高

E-III 边界级（事实/格式）：

特征	计算方式	退化信号
eiii_proper_case_ratio	首字母大写单词 / 总词数（英文） / 专名标注率（中文）	大小写/标注规约丢失时下降
eiii_number_integrity	保持原样的数字个数 / 总数字个数	数字被篡改/四舍五入时下降

自适应分块：长文本（>300 tokens）自动切片到 Goldilocks 区（80–200 tokens），取各块特征均值，避免长文本饱和效应。

语言自动检测：中/英文使用各自独立的连接词库和分词逻辑。

2.2 特征 → 约束状态（S_n）

8 个特征经加权映射为 5 维约束状态：

$$\begin{aligned} \text{sigma_syntax} &= 0.65 \times \text{ei_logic_density} + 0.35 \times \text{ei_syntax_cv} && [\text{E-I}] \\ \text{sigma_style} &= \text{unique_word_ratio} \times (1 - 0.5 \times \text{bigram_rep} - 0.3 \times \text{trunc} - 0.2 \times \text{filler}) && [\text{E-II}] \\ \text{sigma_fact} &= 0.55 \times \text{proper_case_ratio} + 0.45 \times \text{number_integrity} && [\text{E-III}] \\ \text{sigma_coherence} &= 0.55 \times \text{ei_logic_density} + 0.45 \times (1 - \text{bigram_rep}) \end{aligned}$$

$\sigma_{\text{safety}} = 0.5$ (中性)

$S_n = (\sigma_{\text{fact}} + \sigma_{\text{syntax}} + \sigma_{\text{style}} + \sigma_{\text{safety}} + \sigma_{\text{coherence}}) / 5$

$S_n \in [0, 1]$ 。每个样本一个 S_n ，同代同能力维度的样本取均值得到该代该能力的约束基线。

权重来源：各权重 (0.65/0.35、0.55/0.45 等) 经 4 模型 (Qwen/Sonnet/Haiku/Opus) 实验校准，与 LLM judge (Claude) 在该维度的 Spearman 相关性成比例——相关性高的特征权重高。E-I 相关性 0.93，E-II 0.98，E-III 0.27——所以 E-III 维度权重整体偏低，优先使用 LLM judge (如可用)。

2.3 S_n 代际序列 $\rightarrow \beta$ 拟合

对每个能力维度，跨代追踪 S_n 序列，拟合指数衰减模型：

$$S_n = S_0 \times (1 - \beta)^n$$
$$\log(S_n / S_0) = n \times \log(1 - \beta)$$

用最小二乘线性回归估计斜率 $k = \log(1-\beta)$ ，反推 $\beta = 1 - e^k$ 。

β 钳制在 $[0.03, 0.55]$ 内 (低于 0.03 为噪声，高于 0.55 意味着 3 代内完全坍缩——实际中极少出现)。

全局 β 为各能力维度 β 的算术平均，作为模型的”递归稳定性总分”。

2.4 退化状态分类

S_n 范围	状态	含义
> 0.80	healthy	约束结构完整
$0.50-0.80$	degrading	开始退化
$0.30-0.50$	critical	接近坍缩
< 0.30	collapsed	已坍缩

预测坍缩代数：当 $S_n < 0.30$ 时判定为坍缩。基于拟合曲线 $S_n = (1-\beta)^n$ ，求解 $n = \log(0.30) / \log(1-\beta)$ 。

2.5 执行者类型诊断

从跨代 σ 变化率 + 文本特征指纹，自动判断退化主要由哪种执行者失效导致：

- **E-I 退化：**逻辑连接词丢失 + 句法 CV 上升 $\rightarrow$ 推理链断裂 $\rightarrow$ 干预：加 chain-of-thought 校准
- **E-II 退化：**bigram 重复上升 + 词汇多样性下降 $\rightarrow$ 风格坍缩 $\rightarrow$ 干预：提高 temperature 或换模型
- **E-III 退化：**大小写/数字规约丢失 $\rightarrow$ 边界侵蚀 $\rightarrow$ 干预：加输出格式约束

三、技术架构

3.1 系统总览

decaymonitor.ai	
前端 (React)	后端 (FastAPI)
β 排行榜	POST /eval → 异步评测
模型详情页	GET /leaderboard → β 数据
6 维衰减曲线	GET /model/{id} → 完整报告
评测引擎 (ExperimentRunner)	
ProviderAdapter → 12 seeds × 3 gen → DecayEngine	
纯文本特征模式 (CPU) – 秒级完成	
可选 LLM Judge 模式 (GPU) – 更高 E-III 精度	
定时调度 (Celery)	数据层 (PostgreSQL + S3)
每周一自动评测	lineage JSONL 归档
新模型上线即测	β 历史曲线
模型更新复测	实验元数据 (API 成本/时间)

3.2 评测流水线

每周自动运行：

- 1. **模型发现**：从 providers.json 读取待评测模型列表（手动维护 + API 自动发现）
- 2. **调度**：Celery 分发评测任务到 worker（每个模型一个独立任务）
- 3. **生成**：ExperimentRunner.run_generation() — 12 seeds × 3 gens → JSONL
- 4. **分析**：DecayEngine.run_all_capabilities() → 6 能力 β + 全体 β
- 5. **存储**：结果入库 (PostgreSQL)，JSONL 归档
- 6. **发布**：更新排行榜缓存 (Redis)，刷新前端

单个模型评测耗时：12 seeds × 3 gens × 0.5s sleep ≈ 18 秒（API 调用时间另计，取决于模型延迟）。

3.3 多 Provider 支持（已有）

通过 ProviderAdapter 抽象层，当前支持：

Provider	覆盖模型
QuickRouter	Claude Sonnet/Opus/Haiku
OpenAI	GPT-4o, GPT-4.1, o3-mini
Together AI	Llama 3, Mixtral, DeepSeek
DeepSeek 官方	DeepSeek-V3, DeepSeek-R1
Local (vLLM 兼容)	自部署开源模型

新增 provider 只需实现 ProviderAdapter.generate() 方法。

3.4 评测模式对比

	标准模式（免费榜）	深度模式（付费）
seeds 数	12	100
代数	3	3–5
特征提取	纯文本（CPU）	纯文本 + LLM Judge
执行者诊断	基本	全 E-I/E-II/E-III 分解
训练建议	无	跨能力 β 差异 $\rightarrow$ 数据盲区
完成时间	< 2 分钟	< 10 分钟
费用	\$0.50–2（API 成本）	\$5–20（API 成本）

四、运营计划

4.1 评测覆盖路线

Phase 1（上线时）— 已有数据

模型	家族	β	状态
Qwen2.5–7B–Instruct	Qwen	0.2865	✓ 已有
Claude Sonnet 4.6	Claude	0.3106	✓ 已有
Claude Haiku 4.5	Claude	0.3107	✓ 已有
Claude Opus 4.6	Claude	0.2971	✓ 已有

Phase 2（1 个月内）— 扩展至 10+ 模型

目标：覆盖各主要家族至少一个模型，建立跨家族 β 基线。

模型	家族	优先级	获取方式
DeepSeek–V3	DeepSeek	最高	platform.deepseek.com API
DeepSeek–R1	DeepSeek	高	同上
GPT–4o	OpenAI	高	OpenAI API
GPT–4.1	OpenAI	高	OpenAI API
Llama 3 70B	Meta	高	Together AI
Gemini 2.5 Pro	Google	中	Google AI API
Mistral Large	Mistral	中	Mistral API
o3–mini	OpenAI	中	OpenAI API

Phase 3（3 个月内）— 20+ 模型持续更新

- 每周一自动重测所有模型（捕捉模型更新导致 β 变化）

- 新模型发布 48 小时内上线 β 数据（时效性优势）
- 建立 β 历史曲线（追踪模型迭代对稳定性的影响）

4.2 排行榜设计

首页排行榜： – 全局 β 排名（越低越好） – 6 个能力维度的热力图 – 模型家族标签（一眼看出家族内部 β 分布） – “本周新上榜”和” β 变化”标签

模型详情页： – 6 维衰减曲线（交互式 d3/ECharts 图） – S_n 跨代变化轨迹 – 执行者退化类型诊断 – 同家族模型 β 对比 – 同类模型推荐（ β 更低 = agent 场景更好的选择） – 原始 JSONL 数据下载

特色功能：模型对比 – 选 2-4 个模型，并排对比 $\beta \times 6$ 能力 – 自动标注：“模型 A 在数学推理上比模型 B 稳定 2.3x” – 导出对比报告 PDF

4.3 论文与发布节奏

时间	动作	目标
第 1 个月	P3 严格检验 + DeepSeek/Llama 实验	数据达到可发表水平
第 2 个月	arXiv 论文提交	建立学术可信度
第 3 个月	GitHub 开源全部代码+数据	stars > 500
第 4 个月	decaymonitor.ai 上线 (10+ 模型)	月活 > 1000
第 5 个月	HuggingFace Space demo	零门槛体验
第 6 个月	NeurIPS/ACL workshop 投稿	学术圈曝光

4.4 社区运营

- **新模型首发评测：** GPT-5/Claude 5/Llama 4 发布 → 24h 内出 β 对比，在 Twitter/X 和 Reddit 分发
- **GitHub 开源：** pip install decay-eval → 开发者本地跑评测
- **HuggingFace Space：** 粘贴文本 → 即时 S_n + 退化诊断报告
- **LangChain 集成文档：** 展示如何在 agent 选型时参考 β

五、商业模式

5.1 价值主张

“现有的 LLM 评测告诉你模型能答对多少题。我们告诉你模型在自主循环中能撑多久。”

对于 AI agent 开发者，选模型不能只看 benchmark 分数——benchmark 第一的模型可能在你的 agent loop 里 10 轮就退化到不可用。 β 是多一个决策维度。

5.2 收入来源（三档）

免费档：公开排行榜

- 所有公开模型的 β 排行榜 (12 seeds 模式)
- 模型详情页 + 6 维衰减曲线
- API 免费调用 (限 50 次/天)
- 目的：引流 + 建立权威

Pro 档：闭门评测 (\$499/次)

目标客户： 模型厂商在发布前想私下测试自己的模型

- 完全私密：结果不上榜
- $n=100$ seeds 全量评测
- E-I/E-II/E-III 执行者深度诊断
- 与竞品模型的 β 匿名对比
- 交付：PDF 报告 + 原始数据 CSV/JSONL

为什么值 \$499： 模型厂商在发布前已经在花远高于此的 API 费用做内部评测。 β 报告提供一个他们自己没有的视角 (递归稳定性)，且一次购买即可。

Enterprise 档：持续评测 (\$2,999/月)

目标客户： LLM 训练团队每次出新 checkpoint 都要测

- 无限次评测 (每 checkpoint 一次)
- $n=100$ seeds $\times$ 5 gens 全量评测
- 跨 checkpoint β 历史曲线—追踪训练对稳定性的影响
- 训练数据诊断： β 在 math_reasoning 上 0.40 而在 factual 上 0.08 $\rightarrow$ 数学训练数据缺少自我纠错对
- 专属 API endpoint + Slack 集成
- 季度电话诊断 (我们的研究人员解读 β 变化)

为什么值 \$2,999/月： 训练团队每月几十万的算力成本。 β 跨能力分布的差异能直接指出训练数据的盲区——这是现有评测做不到的。一个 actionable insight 的价值远超 \$2,999。

5.3 收入预测

时间	免费榜模型数	Pro 客户/月	Enterprise 客户	月收入
上线时	4	0	0	\$0
3 个月 (arXiv + 10+ 模型)	10	2–3	0	\$1,000–1,500
6 个月 (HF Space + 社区)	15	5	1	\$5,500
12 个月	25	10	3	\$14,000
24 个月	40+	20	8	\$34,000

5.4 成本估算

固定成本（月）：

项目	费用
服务器（Hetzner/DO, 4 vCPU）	\$50
数据库（PostgreSQL, managed）	\$30
域名 + CDN	\$20
网站部署（Vercel/Netlify 免费层）	\$0
小计	\$100

评测成本（月）：

项目	单价	次数	费用
公开榜 12 seeds × 25 模型	\$0.50–2	25	\$50
历史更新 + 复测	\$0.50–2	10	\$20
Pro 深度评测（客户付费）	\$5–20	10	\$0（客户付）
小计			\$70

月总运营成本：~\$170。3 个月后 Pro 收入可覆盖。盈利门槛极低。

5.5 竞争优势（为什么别人不做）

- 1. **先发优势 + 科学护城河**：arXiv 论文 + 跨 4 家族数据 + 理论框架（约束吸引子坍缩）——不是只测了一个分数，是背后有一套可验证的因果理论。抄评测容易，抄理论难。
- 2. **CPU-only 评测**：纯文本特征提取不需要 GPU。Chatbot Arena 需要大规模人类投票，我们的全流程自动化。边际成本接近零。
- 3. **多 Provider 抽象层**：新增模型只需一行配置。别人要支持新 provider 得从头写。我们已经在 3+ 后端验证过。
- 4. **评测维度不可替代**：MMLU 测知识覆盖面，我们测循环稳定性。这两个维度是正交的——加分项，不是替代项。如果行业接受“递归稳定性”是新维度，定义者天然有权威。

六、当前状态与启动条件

6.1 已有资产

资产	状态
理论框架（约束吸引子坍缩 + P1–P4）	✅ 完整
4 模型 β 数据库（Qwen/Sonnet/Haiku/Opus）	✅ 已有

资产	状态
纯文本特征提取器（无需 GPU，E-I/E-II 相关 0.93/0.98）	✅ 可用
ExperimentRunner 统一评测框架（一键跑实验）	✅ 可用
ProviderAdapter 多后端抽象（QuickRouter/OpenAI/Local）	✅ 可用
pyproject.toml / requirements.txt	✅ 就绪
FastAPI 后端基础（server.py）	⚠️ 需适配

6.2 补足第一层科学严谨性（启动前提）

缺失项	条件	费用	优先级
n=100 seeds 验证	API 费用 + 时间	~\$126	高
P3 严格检验	GPU 机器（需 Window-1 管线）	\$0（本地）	最高
DeepSeek 家族 β	DeepSeek API key	~\$5	高
Llama 家族 β	Together AI API key	~\$10	高
多 temperature 稳健性	API 费用 ×3	~\$100	中

总费用 < \$300。真正瓶颈是 GPU（P3 严格检验）。

6.3 网站开发（论文后可启动）

- React 前端（排行榜 + 模型详情 + 对比页）— 复用论文图表组件
- FastAPI 后端适配 — server.py 已有基础
- PostgreSQL + Redis — 标准运维
- Celery 定时任务 — 每周自动评测

MVP 网站开发量：2–3 周（1 人全职）。论文审稿期间即可并行开发。

七、路线图

Month 1–2	Month 3	Month 4–5	Month 6–12
P3 严格检验	→ arXiv 投稿	→ 网站 MVP 上线	→ 10+ 模型 持续更新
n=100 验证	GitHub 开源	10+ 模型 β 榜	Pro 客户增长
DeepSeek/Llama		HF Space Demo	Enterprise 试点
论文写作			
└ 当前 ┐			

八、关键风险

风险	概率	影响	缓解
β 在 $n=100$ 时不显著	中	高	先做 $n=100$ ，结果不好不投论文
没有模型厂商愿意付费评测	中	中	免费榜先建权威 → 付费是自然延伸
大模型公司自己做	高	低	他们只能测自己，我们跨模型视角不可替代
竞品出现	中	中	论文+开源建立先发优势，6 个月窗口
纯文本特征被质疑准确性	低	中	论文中公布与 LLM judge 的 Spearman 对比数据

结论：评测平台是研究路线的自然终点——论文建科学可信度，排行榜建行业权威，Pro/Enterprise 体检单变现。成本极低（\$170/月运营），不需要说服市场创造新需求，只需要在已有的评测清单上加一行。