

DecayMonitor 闭源信任策略

DecayMonitor 闭源信任策略


核心命题

不开源代码。但让任何理性第三方都相信 β 值是真的。

目录

- 信任三角框架
- 支柱 1：论文方法论——公开配方
- 支柱 2：统计透明度——数据指纹
- 支柱 3：第三方验证路径
- 常见攻击及应对
- 发布执行清单

一、信任三角框架



三个支柱互相支撑。缺一个，另外两个要更强。

信任的本质：不是“我证明给你看我是对的”，而是“你可以不相信我，但你无法造出同样的假”。

二、支柱 1：论文方法论——公开配方

2.1 类比

开餐厅不让你进后厨。但菜单上写清楚：这道菜用了什么食材、什么烹饪方法、几克盐、多大火候。你回家自己做，味道应该差不多。做不出来是你手艺问题，不是菜单撒谎。

2.2 论文中必须公开的内容

第 3 章：方法（详细到可复现）

3.1 8 个文本特征——完整定义 + 数学公式

对每个特征，给出：- 精确的数学定义（公式） - 一个计算示例（输入一段文本，输出一个数值，手算可验证）

示例格式：

特征 1: `ei_logic_density`（逻辑连接词密度）

定义：文本中逻辑连接词出现的次数 / 文本总词数

逻辑连接词集合 $L = \{\text{therefore, thus, hence, because, since, consequently, accordingly, as a result, if, then, however, although, whereas, nevertheless, moreover, furthermore, additionally, in contrast, on the other hand, first, second, finally, in conclusion, to summarize}\}$

$$\text{ei_logic_density}(\text{text}) = \frac{\text{count}_{\{w \in \text{text}\}}(w \in L)}{\text{total_words}(\text{text})}$$

计算示例：

输入: "If it rains, then the ground gets wet. Therefore, we should bring an umbrella."

总词数: 18

逻辑连接词: if, then, therefore → 3 个

$\text{ei_logic_density} = 3/18 = 0.167$

关键：这样写，任何懂 Python 的人都能在 10 分钟内自己实现这个特征。

附录 A：100 个种子 Prompt 全文（必放）

论文附录逐行列出所有种子 prompt，格式：

种子 #	能力维度	Prompt 全文
1	math_reasoning	Prove that the square root of 2 is irrational using proof by contradiction. Show each step clearly.

2	math_reasoning	Solve the integral of $x \cdot \sin(x)$ from 0 to π , explaining the integration by parts method.
...	...	...
100	general	Compare and contrast renewable energy sources (solar, wind, hydro) in terms of efficiency, environmental impact, and scalability.

这是最关键的复现性保证。任何人拿到这些 prompt，用任何模型自己跑，可以：1. 跑完 100 个种子 $\times$ 3 代 2. 对自己的输出，按论文公式算 Π 值 3. 对比我们公布的 Π 值是否在自己算的范围内

不需要我们的代码，不需要我们的数据。

附录 B： β 计算完整流程——伪代码

论文附录 B： β 计算伪代码

输入：某个能力维度下，4 代 (Gen0-3) 的文本样本集
每代有 n 个样本 ($n=100$ 个种子在该能力的子集)

步骤 1：对每个样本提取 8 维特征

```
for each sample in all_samples:
    features = [
        ei_logic_density(sample.text),
        ei_syntax_cv(sample.text),
        eii_bigram_repetition(sample.text),
        eii_filler_ratio(sample.text),
        eii_unique_word_ratio(sample.text),
        eii_truncation_ratio(sample.text),
        eiii_proper_case_ratio(sample.text),
        eiii_number_integrity(sample.text),
    ]
```

步骤 2：映射到 5D σ 空间

```
sigma_fact      = w_1*features[6] + w_2*features[7]
sigma_syntax    = w_3*features[0] + w_4*features[1]
sigma_style     = w_5*features[2] + w_6*features[3] +
                w_7*features[4] + w_8*features[5]
sigma_safety    = ... # 公式
sigma_coherence = ... # 公式
```

步骤 3：计算代内 Π (代内样本间梯度)

```
for each generation g:
    total_constraint[g] = mean over all sample pairs(i, j) of:
         $\sum_{d \in \{fact, syntax, style, safety, coherence\}} |\sigma_d(i) - \sigma_d(j)|$ 
```

步骤 4：预注册 β 拟合

```
x = [0, 1, 2, 3] # 代数
y = total_constraint # 对应每代的  $\Pi$  平均值
```

```
# 拟合模型:  $y = y_0 * (1-\beta)^x$ 
# 取  $\log: \log(y/y_0) = x * \log(1-\beta)$ 
slope = OLS(x, log(y/y0))
 $\beta = 1 - \exp(\text{slope})$ 

# 步骤 5: Bootstrap 置信区间
for b = 1 to 500:
    从每代样本中有放回重采样
    重新计算步骤 3-4
 $\beta\_CI\_95 = [\text{percentile}(\beta\_bootstrap, 2.5), \text{percentile}(\beta\_bootstrap, 97.5)]$ 
```

这就是”公开配方”的粒度。 够详细到可以独立实现，但不给任何优化细节。

2.3 论文中不必公开的内容

保留项	原因
5D σ 映射的具体权重矩阵	核心 IP，论文给方向不给参数
特征提取的 Python 实现	公式已公开，实现是你的私有财产
Bootstrap 采样策略（分层/平衡）	优化细节
原始 JSONL 数据文件	商业资产，Pro 用户付费获取
种子扩展算法	提升 $n>36$ 时的 prompt 生成方法

三、支柱 2：统计透明度——数据指纹

3.1 核心概念

“数据指纹”= 一组统计特征，它们内部有严格的数学约束关系。伪造数据会破坏这些约束。

类比：银行不会给你看所有人的账户余额，但公布”总存款/账户数/标准差”等统计量。如果有人质疑，统计量之间的矛盾会暴露造假。但真实数据天然满足这些约束。

3.2 我们的数据指纹

指纹 1：Bootstrap CI 与 $n=100$ 的理论约束

约束关系：对于任意 β 值，Bootstrap CI 宽度 = $f(\beta, n, \sigma_sample)$ 。 $n=100$ 时，这个函数有确定的取值范围。

公布方式：

模型	β	CI_low	CI_high	CI_width
DeepSeek-V3		0.0281	0.018	0.039
				0.021

GPT-4o-mini	0.0885	0.082	0.095	0.013
...	...	...	...	...

为什么不能造假：如果你想编造一个 $\beta=0.0885$ 但实际是 0.20 的模型，Bootstrap 重采样会暴露真实的方差——CI 宽度会异常大或小。没有代码但懂统计的人一眼能看出来。

指纹 2：测试-重测等价性

约束关系：两次独立实验的 β 值应该在彼此的 95% CI 范围内。如果 CI 宽度是 0.013，那么两次 β 差 > 0.02 就触发警报。

公布方式：

```
GPT-4o-mini
Run 1:  $\beta=0.0885$   CI=[0.082, 0.095]
Run 2:  $\beta=0.0885$   CI=[0.081, 0.096]
 $\Delta = 0.0000$     (完美复现)
```

为什么不能造假：编造的数据在不同次实验间很难恰好一致。真实实验的 $\Delta=0.0000$ 是极其有力的证据。

指纹 3：家族内 β 一致性

约束关系：同一家族、不同规模的模型， β 高度一致。因为递归稳定性主要由训练策略和解码行为决定，而非参数量。

公布方式：

家族	模型	β	家族范围	
Llama	70B	0.0925	0.0017	← 几乎相同
	8B	0.0942		
OpenAI	GPT-4o	0.0985	0.0100	← 几乎相同
	GPT-4o-mini	0.0885		
Claude	Sonnet	0.1055	0.0413	← 轻微差异
	Opus	0.1196		
	Haiku	0.1468		

为什么不能造假：如果数据是编的，很难让 Llama 8B 和 70B——两个规模和训练方法都完全不同的模型——恰好 β 仅差 0.002。这种跨模型的自治性只有真实数据才能产生。

指纹 4：跨能力的层级衰减模式

约束关系：E-II（风格层 $\alpha=0.20$ ）的衰减应始终快于 E-III（事实层 $\alpha=0.08$ ）。所有模型、所有能力的 Π 分量必须满足这个层级顺序。

公布方式（每个模型的报告里展示）：

能力	$\Sigma \nabla\sigma_{EI} $	$\Sigma \nabla\sigma_{EII} $	$\Sigma \nabla\sigma_{EIII} $	层级顺序验证
math	0.042	0.078	0.012	$EI < EII > EIII$ ✓

creative	0.018	0.145	0.008	EI < EII > EIII ✓
factual	0.011	0.023	0.015	EI < EII > EIII ✓

为什么不能造假：要对 9 个模型 × 6 个能力 = 54 个场景同时满足层级顺序约束，编造的成本是指数级的。

指纹 5：creative_writing 9/9 崩溃

约束关系：creative_writing 的 Gen3 S_n 在所有 9 个模型中 < 0.5。如果有一个模型异常（比如 S_n=0.9），说明要么造假，要么那个模型有特殊性（需要解释）。

公布方式（热力图）：

	math	code	fact	logic	creat	general
DeepSeek-Chat	H	H	H	H	C	H
GPT-4o-mini	D	H	H	H	C	C
...						
	9/9 H	9/9 H	9/9 H	8/9 H	9/9 C	3/9 H

为什么不能造假：9 个独立实验全部指向同一个结论——creative_writing 最先崩溃。这种跨实验的一致性比任何单一数据点都难伪造。

3.3 数据指纹的呈现方式

每个模型报告 → 模型详情页：

GPT-4o-mini

OpenAI Family

β=0.0885

Rank #2

Reliability Evidence:

✓ Test-retest Δ = 0.0000

✓ Bootstrap CI [0.082, 0.095]

✓ Bootstrap n=500, converged

✓ Family consistency verified

✓ Hierarchy α_{EII} > α_{EIII} verified

S_? trajectory (6 capabilities):

[折线图]

Constraint breakdown:

[代际 Π 分量表]

每个可信信号前打 ✓。访问者不需要懂统计，看到一排 ✓ 就信了。

四、支柱 3：第三方验证路径

4.1 四级验证体系

Level 1：自验证（任何人，0 成本）

- 用论文附录的 100 个种子 prompt
- 调任何模型的 API 自己跑一代
- 看文本是否有明显退化（不用算 β ）
- 结论：“确实，跑一代就肉眼可见变差了”

Level 2：独立复现（研究生/工程师，1 天）

- 按论文第 3 章伪代码自己实现
- 用自己的模型跑一遍
- 算自己的 β 值
- 和我们公布的 β 做对比
- 结果可能在 CI 内 → 确认。可能略有偏差 → 因为实现细节不同

Level 3：背对背验证（独立研究团队，1-2 周）

- 我们邀请一组独立研究者
- 给他们种子 prompt + 方法论
- 他们用自己的基础设施独立跑实验
- 对比 β 值是否在彼此 CI 内
- 联合发布验证声明

Level 4：厂商内测交叉验证（最有力）

- 某 LLM 厂商内部有自己的递归稳定性测试
- 他们看到我们的 β 排名
- 如果排名和他们的内部数据一致 → 默认背书
- 如果排名不一致 → 他们可能公开质疑
- 如果他们沉默 → 默认真实

4.2 如何启动验证链

我们不能被动等别人来验证。要主动制造。

具体操作：

1. 论文发布当天，在 Twitter/知乎同时发：> “DecayMonitor β 排名发布。所有 β 值的计算方法在论文第 3 章详细描述。你不需要我们的代码——附录 A 有 100 个种子 prompt，附录 B 有伪代码。欢迎独立验证。”
2. 论文发布一周后，联系 2-3 个独立 AI 研究者/博主：> “我们想邀请你做 DecayMonitor 的独立验证。我们可以提供种子 prompt 和 β 计算方法（论文中已公开），你用你自己的代码实现并验证。无论结果如何，我们不会干预你的结论。”
3. 模型厂商 1-2 个月后，追踪新模型发布：> “XX 发布了新模型 YY。根据我们的 β 评测，它的稳定性排名是 Z。我们欢迎 XX 内部团队验证这一排名。”

4.3 不可验证的部分（诚实声明）

在论文讨论部分明确指出：

“以下方面目前无法被独立第三方验证：(1) 5D σ 映射的具体权重——这些权重是约束残差框架的可调参数，我们选择使其在各能力维度上保持固定以维持预注册承诺；(2) 原始 JSONL 生成数据——但完整方法论允许任何第三方重新生成等价数据。我们欢迎对这些映射参数敏感性的独立分析。”

提前声明“不可验证”，比被人发现后被迫承认——信誉损失完全不同。

五、常见攻击及应对

攻击 1：“你选择性报告了对自己有利的模型”

应对：公布模型选择标准：- 覆盖 4 个模型家族 - 每个家族至少 2 个模型 - 选择了当时可通过公开 API 访问的主要模型 - 预注册方法：所有模型使用相同方法，禁止 post-hoc 筛选

额外防线：开放“Request a Model”通道。用户提名模型，我们公开回应是否测试及原因。

攻击 2：“你的 β 值依赖特定种子，换种子就不一样了”

应对：- 种子敏感性测试已做： $\Delta=0.005$ ，可忽略 - 测试-重测：同种子 $\Delta=0.000$ ，不同种子 $\Delta=0.005$ - 论文公开 100 个种子全文，任何人都可以用不同的种子验证

攻击 3：“ $\beta=0.028$ 到 0.147 的差别有意义吗？ 0.12 的差距在实际应用中重要吗？”

应对：- 用 S_n 轨迹翻译成直观语言： $\beta=0.028 \rightarrow \text{Gen3 } S_n=0.92$, $\beta=0.147 \rightarrow \text{Gen3 } S_n=0.62$ - 到 Gen10： $\beta=0.028 \rightarrow S_n=0.74$, $\beta=0.147 \rightarrow S_n=0.20$
- 实际应用场景：如果每天迭代一次， $\beta=0.147$ 的模型 5 天后质量减半

攻击 4：“你的特征提取太简单，测不到真正的质量退化”

应对：- P3 神经验证：特征衰减与约束吸引子坍塌 ($\lambda_C=+0.0415$, $R^2=0.884$) 一致 - LLM judge 验证：独立 judge 也确认 Gen1 > Gen3（整体层面） - “简单”是特性，不是 bug——复杂的 judge 模型会引入 judge bias - 类比：体温计很简单，但它能测出发烧。我们测的是“结构坍塌”，不是“写得好看不好看”

攻击 5：“你是独立研究者，没有机构背书，数据可信度低”

应对：- 所有结论都带置信区间，统计严谨性对标学术标准 - 主动寻求独立验证（支柱 3） - 论文提交 arXiv，接受同行评议 - 反驳逻辑：“独立研究者不等于不可信。数据和方法的透明度决定可信度，而不是作者的单位。”

六、发布执行清单

论文发布前（D-3）

☐

附录 A：100 个种子 prompt 逐条列出，附能力标签

☐

附录 B： β 计算伪代码（完整流程，所有公式）

☐

第 3 章：8 个特征每个带数学定义 + 手算示例

☐

所有 β 值报告格式改为： $\beta \pm \text{CI}$

☐

讨论部分加入“不可验证声明”

☐

论文标注：预注册方法、禁止 post-hoc、固定拟合模型

网站上线前（D-1）

☐

每个模型详情页展示“可靠性证据面板”（5 个 ✓）

☐

Methodology 页面：公开论文第 3 章全量内容

☐

“How to Verify”页面：4 级验证路径说明

☐

排行榜每个 β 值旁显示 95% CI

☐

每页底部：“All β values are pre-registered. Methodology and verification guide available [link].”

发布当天

☐

论文 arXiv 提交

☐

Twitter 线程： β 排名 + 验证邀请

☐

- ☐ 知乎文章：完整方法论中文解读 + 验证邀请
- ☐ GitHub 仓库：README 不含实现代码，含论文链接 + 验证指南

发布后 1 周

- ☐ 联系 2-3 个 AI 研究者/博主做独立验证
- ☐ 回复所有公开的技术质疑（快速、透明、有数据）
- ☐ 持续记录所有第三方验证结果

持续运营

- ☐ 每季度发布 β 排行榜更新报告
- ☐ 每份报告含：方法一致性声明 + 任何方法变更的 Changelog
- ☐ 对新发布模型 24h 内给出 β 评测结果